

ÉVALUATION DES PERFORMANCES D'UN GRAND MODELE DE LANGAGE EN CONTEXTE D'AIDE AU DIAGNOSTIC CLINIQUE : ANALYSE DE L'IMPACT DE LA REFORMULATION DU PROMPT

Rapport final - Projet d'application LLMQ - Ingénieur 2 (2N/2NS)

Résumé. Les grands modèles de langage suscitent un intérêt croissant dans le domaine médical, notamment pour l'assistance à l'interprétation de résultats biologiques et à la prise de décision clinique. Cependant, leur sensibilité à la formulation des requêtes ce qui est un phénomène connu sous le terme de sensibilité au prompt constitue un risque majeur dans des contextes où la reproductibilité et la sécurité sont primordiales.

Ce projet étudie de manière expérimentale l'impact de la reformulation d'un même cas clinique sur la qualité, la sécurité et la stabilité des réponses produites par trois modèles de langage (LLaMA 3.1 8B Instruct, Gemma3 27B et Qwen 2.5 32B) déployés localement via Ollama dans un environnement contrôlé. Le protocole s'appuie sur 15 cas cliniques synthétiques issus d'annales d'endocrinologie et chacun sont décliné en trois formulations (narrative, condensée, reformulée) puis soumis trois fois, soit 135 exécutions par modèle. Les réponses sont analysées à l'aide d'une grille d'évaluation par un expert clinicien pour déterminer l'exactitude des réponses, la sécurité des recommandations ainsi que la présence d'hallucinations. L'analyse statistique combine des tests adaptés aux mesures (Friedman, Cochran Q, Spearman pour les évaluations de l'expert) et des métriques automatiques (BERTScore, ECE).

A ce jour, les résultats disponibles portent sur le modèle Qwen 2.5 32B pour la grille experte et sur les trois modèles pour les métriques automatiques indiquant que la reformulation influence significativement l'exactitude clinique des réponses ($p = 0,007$). Il est noté un effet concentré sur la paire narratif versus reformulé. La confiance auto-déclarée reste stable quelle que soit la qualité de la réponse révélant une surconfiance systématique (avec $ECE = 0,359$ et $\rho = 0,233$). Aucune recommandation dangereuse n'a été produite pour le modèle Qwen 2.5 32B. Ces observations confirment la nécessité d'une standardisation des pratiques d'interrogation des LLM en contexte clinique et soulignent l'importance d'une validation experte systématique avant tout usage médical de ces outils.

Abstract. Large language models are attracting growing interest in the medical field, particularly for assisting with the interpretation of biological results and clinical decision-making. However, their sensitivity to query formulation known as prompt sensitivity represents a major risk in contexts where reproducibility and safety are paramount.

This project experimentally investigates the impact of reformulating the same clinical case on the quality, safety, and stability of responses generated by three language models (LLaMA 3.1 8B Instruct, Gemma3 27B, and Qwen 2.5 32B) deployed locally via Ollama in a controlled environment. The protocol is based on 15 synthetic clinical cases drawn from endocrinology examination materials, each declined into three reformulation types (narrative, condensed, reformulated) and repeated three times, yielding 135 executions per model. Responses are evaluated using a multi-criteria grid validated by a clinical expert, covering biological accuracy, safety of recommendations, presence of hallucinations, quality of argumentation, and declared confidence. Statistical analysis combines inference tests adapted to repeated measures (Friedman, Cochran Q, Spearman) and automatic metrics (BERTScore, ECE).

Results available at this stage covering the expert grid for Qwen 2.5 32B and automatic metrics for all three models indicate that reformulation significantly influences clinical accuracy ($p = 0.007$), with the effect concentrated on the narrative versus reformulated pair. Declared confidence remains stable regardless of response quality, revealing systematic overconfidence ($ECE = 0.359$ and $\rho = 0.233$). No dangerous recommendations were produced across the cases studied. These findings confirm the need for standardization of LLM querying practices in clinical contexts and underscore the importance of systematic expert validation prior to any medical use of these tools.

ETUDIANTS :

ADNET Matthieu

CANARELLI Julia

TUTEUR PÉDAGOGIQUE :

M. Sami SOUIHI

REMERCIEMENTS

Nous tenons tout d'abord à remercier l'école ESME pour nous avoir offert l'opportunité de conduire ce projet d'application sur une thématique au croisement de l'intelligence artificielle et de la santé. Ce travail s'inscrit dans une démarche académique rigoureuse et ambitieuse qui nous a permis de développer des compétences techniques, méthodologiques et scientifiques significatives.

Nous souhaitons remercier Mme Yasmina CHENOUNE pour son accompagnement et ses précieux conseils tout au long de ce projet, ses remarques ont contribué à affiner notre réflexion.

Nous remercions notre tuteur pédagogique M. Sami SOUIHI, pour sa disponibilité, ses retours constructifs et sa capacité à adapter son encadrement au niveau et aux besoins des membres du groupe. Ses orientations nous ont aidés à structurer notre réflexion et nos choix ainsi qu'à progresser de manière cohérente tout au long de ce semestre.

Nous adressons des remerciements au Dr Jean CANARELLI, médecin biologiste et clinicien, Président du Conseil départemental de l'Ordre des médecins de Corse du Sud. Nous remercions également l'interne en Cardiologie Chjara-Maria TOMASI. Ils ont accepté de participer bénévolement à ce projet en qualité d'expert clinique. Grâce à leur contribution au remplissage de la grille d'évaluation, il a été possible de conférer une validité médicale à notre protocole expérimental et ainsi atteindre un niveau de rigueur clinique valide.

Enfin, nous remercions l'ensemble des enseignants et intervenants de l'ESME et de SUPBIOTECH qui, par leurs cours et leurs échanges, ont contribué à notre formation d'ingénieur et nous ont dotés des outils nécessaires à la conduite de ce projet.

AVANT PROPOS

Ce rapport s'inscrit dans le cadre du projet d'application de deuxième année du cycle ingénieur de l'ESME, intitulé LLMQ (Large Language Model en contexte médical de Questions biologiques). Il constitue le livrable final d'un travail mené sur l'ensemble de l'année académique 2025-2026, dont le rapport de mi-parcours, rédigé en avril 2026, avait posé les bases théoriques et méthodologiques.

Le projet se situe à l'interface de deux domaines en pleine expansion : l'intelligence artificielle générative et la médecine de précision. Entre l'essor des Large Language Models (LLM) et leur utilisation dans le secteur de la santé, cela soulève des questions fondamentales sur leur fiabilité et la sécurité de leurs recommandations. Dans des contextes à hauts enjeux tel que l'interprétation de contexte médicale pour l'aide au diagnostic, la fiabilité des outils utilisés dans la prise en charge pouvant impacter les décisions est particulièrement importante.

Ce travail ne prétend pas aboutir à un outil clinique directement déployable. Il vise avant tout à construire un protocole d'évaluation rigoureux, à documenter le comportement d'un LLM dans des conditions expérimentales contrôlées, et à contribuer à la réflexion collective sur l'intégration responsable de ces systèmes dans les pratiques médicales. Les recommandations des organismes de référence tels que le National Institute of Standards and Technology (NIST, 2023) et l'Organisation mondiale de la santé (OMS, 2021) insistent sur la nécessité d'une évaluation systématique avant tout déploiement d'un système d'IA dans un environnement critique, c'est dans ce contexte que se positionne nos travaux.

La problématique centrale du projet porte sur l'impact de la reformulation du prompt c'est-à-dire la manière dont une question est formulée, sur la qualité, la sécurité et la stabilité des réponses produites par un LLM dans un contexte d'aide au diagnostic. Si un modèle peut produire des réponses significativement différentes à partir d'un même cas clinique formulé différemment alors sa fiabilité en conditions réelles doit être sérieusement interrogée.

TABLE DES MATIERES

INTRODUCTION	6
ÉTAT DE L'ART	8
1. Fondations et architecture des grands modèles de langage.....	8
a. Définition et principe général	8
b. Architecture Transformer	9
c. Enjeux et utilisation des LLM en santé	10
2. Limites des LLM	10
a. Fiabilité des sorties : données, hallucinations et calibration	10
b. Biais et équité : origines, formes et implications	11
c. Sensibilité au prompt et stabilité	11
3. Méthodes et approches existantes d'évaluation et de réduction des risques.....	12
a. Cadres institutionnels de gestion des risques	12
b. Approches d'évaluation expérimentale.....	12
4. Les modèles retenus	13
a. Architecture technique du modèle 1 : LLaMA 3.1 8B Instruct	13
b. Architecture technique du modèle 2 : Gemma3 27B Google DeepMind.....	14
c. Architecture technique du modèle 3 : Qwen 2.5 32B Alibaba Cloud.....	14
MÉTHODOLOGIE ET PROTOCOLE EXPÉRIMENTAL	16
1. Objectifs expérimentaux et hypothèses	16
a. Objectifs expérimentaux mesurables.....	16
b. Hypothèses de travail (issues des objectifs)	17
2. Données et constitution du jeu d'étude	17
a. Nature et origine des données	17
b. Variables minimales par cas	17
c. Critères d'inclusion et d'exclusion.....	18
d. Typologie des reformulations	18
3. Déploiement technique et sécurité.....	18
a. Infrastructure de déploiement.....	18
b. Configuration d'inférence et reproductibilité	18
c. Sécurité et conformité RGPD.....	18
4. Grille d'évaluation multicritère	19
5. Analyse statistique	20
a. Niveau 1 : Analyse descriptive	21
b. Niveau 2 : Tests d'inférences statistiques	21
c. Niveau 3 : Métriques de qualité des réponses	22

RESULTATS	24
1. Niveau 1 : Analyse descriptive	24
2. Niveau 2 : Tests d'inférences statistiques.....	27
Modèle : LLaMa 3.1 8B Instruct	27
Modèle : Gemma3 27b	27
Modèle : Qwen2.5 :32b	27
3. Niveau 3 : Métriques de qualité des réponses	30
a. BERTScore	30
b. ECE	32
DISCUSSION.....	34
1. Limites des résultats.....	34
2. Comparaison avec la littérature	34
PERSPECTIVES.....	36
1. Perspectives cliniques et expérimentales	36
2. Perspectives statistiques et métriques	36
CONCLUSION.....	37

INTRODUCTION

Ces dernières années ont été marquées par l'émergence et la diffusion massive des grands modèles de langage (Large Language Models, LLM). Ces systèmes sont fondés sur des architectures de type Transformer et sont capables de générer du texte en réponse à une instruction formulée en langage naturel, communément appelée « prompt ». Ils ont une capacité à produire des réponses fluides et structurées, considérée pertinentes dans des domaines très variés tant auprès du grand public que dans les milieux professionnels spécialisés.

Il est néanmoins essentiel de comprendre ce que ces modèles font réellement car ils ne raisonnent pas tel que le ferait une personne. Les réponses qu'il fournit sont issu d'une modélisation où des distributions statistiques sont attribuées à des données textuelles et génèrent une continuité probable à partir d'un contexte donné (le prompt de utilisateur). Cette distinction est fondamentale et oppose plausibilité linguistique et fiabilité factuelle, enjeux scientifiques soulevés par leur déploiement de ces outils dans des contextes sensibles.

Le secteur de la santé n'échappe pas à cette transformation. Plusieurs travaux montrent que les LLM obtiennent des scores élevés sur des examens médicaux standardisés (Garabet et al., 2024 ; Nori et al., 2023). Ces résultats ont alimenté un intérêt croissant pour leur utilisation en tant qu'outils à implémenter dans la prise en charge patient pour l'aide au diagnostic, le résumé de dossiers patients, ou encore de génération de compte-rendu par exemple. C'est dans ces applications que réside un potentiel considérable notamment dans des contextes de sous-effectif médical.

Cependant, les performances observées sur des benchmarks ne garantissent pas un comportement fiable en conditions réelles. Une étude clinique majeure publiée dans Nature Medicine (Hager et al., 2024) démontre que sur des cas patients réels les LLM sont moins performants que les médecins. Il est noté un manque de cohérence dans le suivi des instructions ainsi qu'une sensibilité à l'ordre et à la quantité d'information énoncé. Ces limites prennent une dimension critique en médecine, où une recommandation erronée peut directement affecter la prise en charge thérapeutique et la sécurité du patient.

Les institutions internationales ont pris la mesure de ces risques. Le National Institute of Standards and Technology (NIST, 2023) insiste sur la nécessité d'une gestion rigoureuse des risques liés à l'IA, incluant la traçabilité, l'équité et la robustesse des systèmes. L'Organisation mondiale de la santé (OMS, 2021) souligne que l'IA en santé doit être conçue et utilisée dans un cadre éthique strict garantissant la sécurité des patients mais également la transparence et le respect des droits fondamentaux. En Europe, le règlement européen sur l'IA (AI Act, 2024) classe les systèmes d'IA à usage médical dans les catégories à haut risque, soumises à des obligations de conformité strictes.

Plusieurs limites des LLM sont documentées dans la littérature incluant sensibilité à la formulation du prompt comme étant un risque particulièrement préoccupant en contexte clinique. Ce phénomène désigne le fait qu'un même contenu de question posée de manières différentes, peut conduire à des réponses différentes parfois contradictoires, sans que cette variation soit cliniquement justifiable. Concrètement, imaginez deux médecins interrogeant un outil LLM pour l'aide au diagnostic sur le même cas. Si l'un formule sa demande de manière narrative et détaillée et l'autre de manière condensée et directe et que les réponses obtenues divergent de manière significative en termes de diagnostic, de recommandations ou de signalement des risques, alors la fiabilité du système est fondamentalement mise en cause. La reproductibilité, pourtant centrale en pratique médicale, est compromise.

Ce problème est documenté dans la littérature scientifique. Zhao et al. (2021) montrent que, dans le contexte du few-shot prompting, la performance d'un modèle peut varier drastiquement selon le format de la question, l'ordre des exemples ou la présence de biais dans les données d'entrée. Ces variations, liées à des biais internes du modèle, ne reflètent pas une adaptation pertinente au contenu clinique mais une instabilité structurelle du système.

De ces réflexions est issue notre problématique :

Dans quelle mesure la reformulation d'un même cas clinique influence-t-elle la qualité, la stabilité, la sécurité et la fiabilité des réponses produites par un grand modèle de langage dans un contexte d'aide à l'interprétation de résultats biologiques, et quelles implications cette instabilité comporte-t-elle pour l'intégration responsable des LLM en pratique médicale ?

Ce projet poursuit plusieurs objectifs complémentaires incluant l'évaluation quantitative de l'impact de la reformulation du prompt sur la qualité des réponses d'un LLM en contexte médical (mesure de performance tel que l'obtention d'un score de fidélité). Ce projet vise également à l'identification des types de reformulations présentant le plus grand risque d'erreur ou d'instabilité.

Le rapport est organisé en plusieurs section. A la suite d'une section dédiée à l'état de l'art sur les LLM et leurs usages en santé, nous présentons les objectifs et hypothèses du projet puis la méthodologie expérimentale en détail incluant une partie statistique (métriques et les méthodes d'analyse). Les résultats obtenus et attendus sont ensuite présentés et discutés. Le rapport se conclut par une section discussion puis perspectives constituant les fondations des étapes à venir.

Résumé exécutif de l'état de l'art. Les grands modèles de langage (LLM) sont des systèmes génératifs fondés sur l'architecture Transformer qui produisent du texte token par token en exploitant des régularités statistiques apprises sur de vastes corpus. Ils ne raisonnent pas au sens humain du terme : la plausibilité linguistique d'une réponse ne garantit pas sa validité factuelle. Les versions « Instruct » des modèles, ajustées par supervised fine-tuning et RLHF, suivent mieux les instructions mais conservent des biais liés aux préférences de leurs annotateurs. Leurs performances apparentes sont élevées, GPT-4 atteint 86 % de réussite sur l'USMLE Step 1 (Garabet et al., 2024), mais trompeuses. Sur des cas cliniques réels, les LLM sont moins performants que les médecins, interprètent incorrectement certains résultats biologiques et sont sensibles à l'ordre et à la quantité d'informations fournies (Hager et al., 2024). Trois limites structurelles sont particulièrement documentées. Les hallucinations désignent la production de contenus factuellement faux mais rhétoriquement convaincants, d'origine mixte : prompt insuffisant ou limites intrinsèques du modèle (Dang Anh-Hoang et al., 2025). La sensibilité au prompt est le fait qu'une variation de la forme de la requête peut produire des réponses différentes (Zhao et al., 2021). Cette limite est particulièrement critique en médecine que chaque professionnel formule ses requêtes différemment, rendant la reproductibilité compliquée en parallèle avec une utilisation réelle. L'AI Act européen (2024) classe ces systèmes en catégorie à haut risque et rend l'évaluation obligatoire. Les approches existantes contiennent des benchmarks standardisés, des grilles expertes multicritères et métriques automatiques telles que BERTScore ce qui permet de mesurer à la fois la qualité des réponses et leur variabilité inter-reformulations. Ce contexte a guidé le choix de centrer l'évaluation sur la stabilité face aux reformulations plutôt que sur la seule performance considérant qu'il s'agit d'une condition nécessaire à tout usage responsable des LLM en pratique médicale.

1. Fondations et architecture des grands modèles de langage

a. Définition et principe général

Les grands modèles de langage (Large Language Models, LLM) peuvent être définis de manière opérationnelle comme étant des systèmes d'intelligence artificielle capables de produire du texte à partir d'une instruction en langage naturel, communément appelé « prompt ». Dans cette logique, l'utilisateur ne « programme » pas explicitement une suite d'actions mais fournit un contexte textuel, parfois sous forme de question, et le modèle génère une continuation statistiquement plausible souvent perçue comme une réponse. Cette définition du LLM « orientée usage » est cohérente avec celle donnée par la société de logiciels IBM qui les définit comme des modèles d'apprentissage profond entraînés sur de vastes corpus de données textuelles afin de comprendre et générer du langage naturel. Ils reposent sur une architecture de réseaux de neurones de type Transformer, particulièrement performante pour modéliser les séquences et capturer les relations contextuelles dans le texte, ce qui leur permet d'accomplir une grande diversité de tâches linguistiques (IBM, n.d.).

Sur le plan computationnel, un LLM « classique » (de type GPT) fonctionne comme un modèle autoregressif. Cela signifie qu'il génère le texte étape par étape. À chaque étape, il prédit le prochain élément du texte en se basant uniquement sur les éléments déjà produits. Cet élément est appelé token et correspond à la découpe du texte en unités de texte (un mot entier ou une partie de mot). Cette étape s'appelle la tokenisation et a pour objectif de transformer une phrase en une suite d'unités plus petites, adaptées au traitement informatique. Une fois le texte tokenisé, le modèle est capable de prédire les tokens un par un, en choisissant le token le plus probable en fonction du contexte précédent et en répétant ce processus il construit progressivement une séquence complète de texte.

Cette idée est formulée par Radford et al. dans l'article présentant GPT-2 qui met en évidence qu'un modèle de langage entraîné sur un très grand corpus peut réaliser plusieurs tâches en *zero-shot*. Cela signifie qu'il n'a pas été spécifiquement entraîné pour ces tâches et qu'il n'y a pas non plus de modification de son architecture ni de phase de *fine-tuning*. Le modèle est donc uniquement entraîné à prédire la suite d'un texte, les données d'entraînement contiennent naturellement des exemples de tâches variées, comme des questions, des traductions ou des résumés, ce qui permet au modèle d'apprendre ces structures de manière implicite.

Lorsque la tâche est formulée dans le texte d'entrée, le modèle est capable de comprendre ce qui est attendu et adapte alors sa réponse en fonction du contexte fourni (Radford et al., 2019).

Une des conséquences les plus importante et souvent mal intégrée dans les usages grand public est que ce mécanisme probabiliste n'implique pas un accès direct au sens que l'on donne à la notion de « vérité ». Il faut comprendre que le modèle n'interroge pas une base de connaissances validée mais recompose une réponse en exploitant des régularités dans les données d'entraînement. Cela explique pourquoi un texte peut être grammaticalement et rhétoriquement excellent et plausible mais factuellement faux. Il faut en conclure que la plausibilité linguistique n'est pas équivalente à la validité scientifique. Les analyses de risque institutionnelles, telles que celle de la NIST, insistent précisément sur ce type d'écart entre performance apparente et fiabilité réelle en particulier pour les systèmes génératifs (NIST, 2023).

b. Architecture Transformer

L'essor des grands modèles de langage (LLM) est étroitement lié à l'architecture Transformer, introduite dans l'article *Attention Is All You Need*. Cette architecture marque une rupture avec les approches précédentes, car elle remplace les mécanismes récurrents (comme les RNN ou les LSTM) par un mécanisme d'attention. Contrairement aux modèles récurrents qui traitent les données de manière séquentielle, le Transformer est un moyen de modéliser directement les relations entre tous les éléments d'une séquence sans dépendre d'une boucle temporelle.

Ce fonctionnement a deux avantages majeurs. D'une part, le modèle peut être entraîné de manière fortement parallélisée ce qui réduit considérablement le temps de calcul. D'autre part, il est capable de capturer des dépendances entre des éléments très éloignés dans le texte ce qui est essentiel pour comprendre le contexte global. Malgré cette parallélisation, le Transformer conserve un fonctionnement autorégressif dans sa partie décodeur, ce qui lui permet de générer le texte token par token.

De manière plus intuitive, le mécanisme d'attention peut être compris comme un système de pondération. Pour chaque token, le modèle analyse tous les autres tokens du contexte et attribue un poids à chacun d'eux en fonction de leur importance. Autrement dit, le modèle « regarde » l'ensemble de la séquence et apprend à identifier quelles informations sont les plus pertinentes pour produire la suite du texte.

Cette interaction entre les tokens repose sur des représentations vectorielles appelées embeddings. Pour chaque token, il y a une transformation en vecteur, puis ces vecteurs sont par la suite modifiés par des couches successives combinant self-attention et réseaux de neurones feed-forward. À chaque couche, la représentation devient plus riche et plus contextualisée. Le modèle construit, via ce processus, progressivement une compréhension du contexte global de la phrase (Vaswani et al., 2017).




Figure 1 - Schématisation du principe de fonctionnement d'un LLM.

Concernant les applications réelles des modèles de langage, il est important de souligner la distinction entre le pré-entraînement sur de vastes corpus de données qui oriente le contenu des réponses et l'alignement du comportement du modèle avec les attentes humaines. Les modèles qui sont pré-entraînés sont souvent qualifiés de modèles « bruts » et sont capables de générer un texte fluide et cohérent. Cependant, ils ne suivent pas nécessairement les instructions de manière fiable et peuvent produire des réponses inadaptées, parfois même incorrectes ou biaisées.

Pour répondre à cette limitation, il y a des méthodes d'alignement qui ont été développées, tel que le fine-tuning qui consiste en la supervision des jeux de données d'instructions ainsi que le Reinforcement Learning from Human Feedback (RLHF). Dans ce cadre, des annotateurs humains comparent différentes réponses générées par le modèle. Ces préférences sont par la suite utilisées pour entraîner un modèle de récompense qui sert ensuite à ajuster le modèle initial par apprentissage par renforcement.

Ce principe est décrit dans l'article *Training language models to follow instructions with human feedback* qui montre que des modèles plus petits mais alignés peuvent être préférés par des évaluateurs humains à des modèles plus grands non alignés. Les auteurs observent également une réduction de certains comportements indésirables comme la production de contenus toxiques ainsi qu'une amélioration de la pertinence et de la véacité perçue des réponses. Toutefois, ces améliorations restent partielles et ne garantissent pas l'absence d'erreurs ou de biais (Ouyang et al., 2022).

c. Enjeux et utilisation des LLM en santé

L'utilisation des LLM en santé permet une grande variété d'applications allant de l'aide à l'interprétation de contexte médical à la génération de résumés de dossiers patients ou rédaction de comptes rendus par exemple. Des études récentes montrent que des modèles comme GPT-4 atteignent des performances remarquables sur des examens médicaux standardisés avec 86 % de réponses correctes sur des questions de type USMLE (Garabet et al., 2024). Nori et al. (2023) confirment ce constat sur GPT-4, soulignant une meilleure calibration que ses versions précédentes, bien qu'insuffisante pour des usages critiques.

Cependant, ces benchmarks présentent des limites importantes : ils reposent sur des questions fermées avec une seule réponse correcte, ne reproduisant pas la complexité du raisonnement clinique réel, qui implique des informations partielles, évolutives et parfois ambiguës. L'étude de Hager et al. (2024) sur 2400 cas de patients réels illustre clairement ces limites car les modèles testés sont moins performants que les médecins et suivent mal les recommandations avec des interprétations incorrectes de certains résultats biologiques. Il est également mentionné une sensibilité du LLM à l'ordre et à la quantité d'informations fournies. Dans ce contexte, l'OMS (2021) appuie la nécessité de concevoir et déployer les systèmes d'IA en santé entourés par un cadre éthique strict garantissant la sécurité, la fiabilité, l'équité et la transparence.

2. **Limites des LLM**

a. Fiabilité des sorties : données, hallucinations et calibration

La fiabilité des LLM repose sur un principe fondamental : ces systèmes modélisent des distributions statistiques du langage à partir de leurs données d'entraînement. Les réponses générées reflètent donc la qualité, la diversité, les biais de ces données et non une compréhension du contenu. Comme le montrent Radford et al. (2019) avec GPT-2, les capacités observées découlent de régularités statistiques apprises, pas d'un accès à une vérité validée.

La qualité des données d'entraînement constitue un premier risque. Selon Bender et al. (2021), les corpus issus du web contiennent des biais constitués par des stéréotypes et des contenus toxiques qu'un modèle peut apprendre et reproduire voire amplifier à grande échelle. Ces corpus sont souvent peu documentés ce qui rend difficile l'identification précise des biais présents. Le NIST (2023) a souligné ce problème sous l'angle de l'opacité car il est difficile d'expliquer pourquoi un modèle produit une réponse plutôt qu'une autre. À ce titre, un système performant en test peut échouer en conditions réelles dès que la formulation change ou que le contexte se complexifie. L'évaluation doit donc reproduire des cas concrets d'utilisation avec des variations de formulation et par conséquent se limiter à des métriques globales.

Les hallucinations constituent un second risque majeur. Ce terme désigne des réponses fluides et cohérentes en apparence mais factuellement fausses ou qualifiables d'inventées. Selon Dang Anh-Hoang et

al. (2025) il est possible de distinguer deux origines à ces hallucinations. Dans un premier temps, celle liées au prompt qui sont réductibles par une meilleure formulation et celles liées au modèle lui-même qui malgré une consigne claire sont toujours présente. En santé, ce risque est particulièrement critique si on considère que la qualité rhétorique du texte peut masquer une erreur factuelle allant jusqu'à induire le clinicien en erreur résultant en des conséquences sur la prise en charge patient. Pour détecter ces hallucinations sans annotation manuelle, Manakul et al. (2023) utilise SelfCheckGPT qui exploite la nature probabiliste des LLM c'est-à-dire qu'une information stable sera reproduite de façon cohérente sur plusieurs générations tandis qu'une information hallucinée variera ou se contredira d'une génération à l'autre. Les travaux de Lin et al. (2022) montrent avec TruthfulQA que l'augmentation de la taille du modèle n'améliore pas nécessairement la véracité car les grands modèles peuvent reproduire plus fidèlement les fausses croyances présentes dans leurs données d'entraînement.

La calibration constitue un troisième risque. Il est considéré qu'un modèle bien calibré exprime une confiance proportionnelle à sa probabilité réelle d'avoir raison c'est-à-dire qu'une confiance de 80 % devrait correspondre à 80 % de réponses correctes sur des cas similaires. Or les réseaux de neurones modernes présente des tendances à être sur-confiants en exprimant un niveau de certitude supérieur à leur justesse réelle (Guo et al., 2017). Dans les LLM génératifs, et pour une utilisation concrète, cette confiance ne se manifeste pas sous forme de probabilité explicite mais indirectement. A travers le ton affirmatif la structure et la précision apparente de la réponse, l'utilisateur peut lui accorder une confiance au-dessus de la réalité. Cela peut renforcer artificiellement la crédibilité d'une réponse incorrecte.

b. Biais et équité : origines, formes et implications

Les biais dans les LLM ne constituent pas de simples erreurs techniques mais reflètent des déséquilibres présents à deux niveaux distincts. Le premier niveau est celui des données de préentraînement issues du web et donc non neutres, contenant stéréotypes, sur-représentations et contenus toxiques (Bender et al., 2021). Le second niveau est celui de l'alignement résidant dans le principe du RLHF qui repose sur les jugements d'un groupe précis d'annotateurs, majoritairement anglophones et dont les préférences ne représentent pas l'ensemble des utilisateurs. Un modèle aligné peut ainsi paraître plus utile ou plus sûr sans être devenu équitable pour tous. Les travaux de Ouyang et al. (2022) montrent d'ailleurs que le RLHF améliore certaines dimensions tel que l'utilité perçue, la réduction des sorties toxiques, le tout sans réduire significativement les biais mesurés sur des benchmarks dédiés. Il est important de retenir que l'équité d'un LLM ne peut donc pas être supposée après alignement mais doit être évaluée explicitement.

En contexte médical, cette question prend une dimension directement clinique. Lorsqu'un même contexte clinique énoncé peut être interprété différemment selon l'âge ou le sexe du patient, en raison des intervalles de référence physiologiques. Le risque n'est pas que le modèle prenne en compte ces variables car c'est médicalement pertinent mais qu'il le fasse de manière incorrecte, si ses données d'entraînement contiennent des biais historiques ou des déséquilibres de représentation.

c. Sensibilité au prompt et stabilité

La dernière limite que nous relevons pour notre analyse au sujet de l'évaluation des LLM est la stabilité des réponses. Cette question est encore plus importante en contexte médical car une réponse qui change facilement selon la manière de poser la question, une situation fréquente lorsqu'on passe d'un médecin à l'autre, est difficile à juger fiable.

Cette instabilité peut venir de deux sources. La première est la « sensibilité au prompt », c'est-à-dire quand le modèle peut répondre différemment selon la formulation ou l'ordre des informations par exemple. La seconde est la « stochasticité du décodage » qui correspond à l'utilisation de paramètres d'échantillonnage comme la température, le top-k ou le top-p, produisant plusieurs sorties différentes pour une même requête. Autrement dit, même si le modèle et la tâche restent les mêmes, le résultat peut varier de façon importante si le prompt et le décodage ne sont pas bien contrôlés.

L'article *Calibrate Before Use: Improving Few-Shot Performance of Language Models*, publié en 2021, montre clairement ce problème. Les auteurs expliquent que en few-shot prompting la performance peut changer fortement selon le format du prompt, les exemples choisis ou leur ordre. Dans certains cas, le niveau obtenu passe de performances proches du hasard à des performances beaucoup plus élevées. Cette instabilité vient

en partie de biais internes du modèle, par exemple lorsque le modèle préfère une réponse fréquente dans ses données d'entraînement, ou favorise une réponse qui apparaît à la fin du prompt.

Dans un projet médical, cela signifie qu'il ne suffit pas d'évaluer un LLM sur une seule formulation de cas. Il faut aussi tester plusieurs formulations proches, contrôler les paramètres de génération, et vérifier que la conclusion reste cohérente, dans le cas contraire une variation purement formelle du prompt peut produire une interprétation différente sans raison clinique valable.

Dans un contexte médical, particulièrement d'aide au diagnostic les professionnels de santé, cette sensibilité a une implication immédiate. Imaginons que deux médecins posent une question médicalement équivalente mais formulée différemment et que celle-ci obtiennent des réponses divergentes. Dans la mesure où un environnement clinique requiert de la reproductibilité, de la traçabilité et une certaine invariance aux reformulations, cela s'avère problématique. Une étude publiée en 2024 dans *Nature Medicine* met en évidence plusieurs limites des LLM dans un contexte décision clinique, notamment que les modèles sont sensibles à la quantité d'information fournie. Elle montre aussi qu'ils sont sensibles à l'ordre dans lequel cette information est présentée et souligne leurs difficultés à suivre les instructions de manière fiable (Hager et al., 2024).




Figure 2 - Schema récapitulatif des limites des LLM et leurs conséquences

3. Méthodes et approches existantes d'évaluation et de réduction des risques

a. Cadres institutionnels de gestion des risques

Le NIST (AI RMF 1.0, 2023) structure la gestion des risques IA en quatre fonctions : gouverner, cartographier, mesurer et gérer. Appliqué en continu sur le cycle de vie du système, ce cadre encourage une évaluation multidimensionnelle intégrant performance, robustesse, équité et traçabilité, au-delà de la seule mesure de performance globale.

Sur le plan éthique, l'OMS (2021) souligne que les systèmes d'IA en santé doivent placer l'éthique, les droits humains et la responsabilité des parties prenantes au cœur de leur conception. Une guidance complémentaire publiée en 2024 cible spécifiquement les modèles génératifs multimodaux, illustrant l'adaptation progressive des recommandations institutionnelles aux nouvelles classes technologiques (World Health Organization, 2021, 2024).

Sur le plan réglementaire, l'AI Act européen (2024) classe les systèmes d'IA à usage médical en catégorie à haut risque et impose des exigences de transparence, de documentation et d'évaluation. L'évaluation des systèmes d'IA devient ainsi une obligation, non une option, pour tout déploiement à fort impact.

b. Approches d'évaluation expérimentale

Il y a trois grandes familles d'approches coexistent dans la littérature.

Les benchmarks standardisés (USMLE, MedQA, TruthfulQA) permettent une comparaison objective entre modèles. GPT-4 atteint ainsi 86 % de réponses correctes sur 1 300 questions de type USMLE

Step 1 (Garabet et al., 2024). Ces tests ont cependant des limites importantes : ils reposent sur des questions fermées avec toutes les informations disponibles, et ne reproduisent pas la complexité du raisonnement clinique réel. TruthfulQA montre par ailleurs que l'augmentation de la taille du modèle n'améliore pas nécessairement la véracité des réponses (Lin et al., 2022).

L'évaluation sur cas cliniques réels constitue une approche plus exigeante. Hager et al. (2024) testent plusieurs LLM sur 2400 cas patients réels concluant que les modèles sont moins performants que les médecins. Leurs résultats révèlent une instabilité liée à l'interaction plutôt qu'au raisonnement médical.

L'évaluation experte via plusieurs critères (sous la forme d'une grille d'évaluation par exemple), permet d'évaluer des dimensions qualitatives inaccessibles aux benchmarks tel que la sécurité des recommandations, la présence d'hallucinations et la qualité de l'argumentation. Elle est complétée par des métriques automatiques comme SelfCheckGPT pour la détection des hallucinations (Manakul et al., 2023) ou BERTScore et ROUGE-L pour la similarité sémantique et la variabilité inter-reformulations.

Justification de nos choix d'objectifs d'évaluation. Trois constats issus de l'état de l'art orientent directement le protocole LLMQ. **Les LLM sont des systèmes probabilistes.** Leurs erreurs et biais ne sont pas des accidents mais des phénomènes structurels à caractériser de manière systématique. **Le contexte médical impose des exigences élevées de sécurité et de reproductibilité.** Le NIST (2023) et l'OMS (2021) recommandent explicitement d'évaluer la robustesse, l'équité et les risques réels d'un système pas seulement ses performances apparentes. **De bonnes performances sur benchmarks ne garantissent pas un comportement fiable en conditions réelles.** Hager et al. (2024) montrent que les LLM sont sensibles à la formulation, à l'ordre et à la quantité d'informations fournies. Ces constats justifient de placer la sensibilité au prompt comme variable expérimentale centrale. Chaque médecin formule sa requête différemment selon son habitude ou la situation rencontrée et cette variabilité est une réalité inévitable de l'usage clinique. L'objectif du projet n'est donc pas de mesurer si le modèle performe dans des conditions idéales, mais **d'évaluer la stabilité, la sécurité et la fiabilité de ses réponses face à la variabilité naturelle des formulations** condition nécessaire à tout usage responsable en pratique médicale.

4. Les modèles retenus

a. Architecture technique du modèle 1 : LLaMA 3.1 8B Instruct

LLaMA 3.1 8B Instruct est développé par Meta AI. Ses caractéristiques officielles, obtenues via ollama show llama3.1:8b, sont l'architecture llama, 8,0 milliards de paramètres, fenêtre de contexte de 131 072 tokens, dimension d'embedding de 4 096, quantization Q4_K_M, capacités de completion et fonction calling, licence LLaMA 3.1 Community License Agreement (juillet 2024).

La famille LLaMA est introduite en 2023 par Touvron et al., qui démontrent qu'il est possible d'obtenir des performances compétitives à partir de corpus publics uniquement. LLaMA 2 (2023) a étendu la fenêtre de contexte à 4 096 tokens et introduit le supervised fine-tuning et le RLHF pour les versions dialogue. LLaMA 3.1 (2024) représente une avancée majeure avec une fenêtre de contexte de 131 072 tokens, avec un vocabulaire de 128 256 tokens et l'adoption du Grouped Query Attention sur l'ensemble de la famille.

Sur le plan architectural, LLaMA 3.1 8B repose sur une architecture Transformer decoder-only causale, générant le texte token par token de gauche à droite. Quatre choix techniques caractérisent la famille : **RMSNorm**, normalisation appliquée en pré-normalisation avant chaque bloc Transformer, plus légère que le LayerNorm classique (Zhang & Sennrich, 2019) ; **SwiGLU**, fonction d'activation à mécanisme de porte dans le réseau feed-forward interne, produisant des représentations plus riches (Shazeer, 2020) ; **RoPE**, encodage positionnel rotatif encodant naturellement les positions relatives et permettant la gestion des longues fenêtres de contexte (Su et al., 2021) ; **GQA** (Grouped Query Attention), où plusieurs têtes de requêtes partagent un nombre réduit de têtes de clés et valeurs, réduisant le coût mémoire tout en maintenant la qualité (Ainslie et al., 2023).

Ce fonctionnement séquentiel et probabiliste justifie directement la sensibilité au prompt avec le fait que deux formulations médicalement équivalentes produisent des séquences de tokens différentes dès la tokenisation, et toute variation initiale se propage et s'amplifie au fil de la génération.

Sur la configuration matérielle utilisée (RX 7900 XTX, 24 Go VRAM), LLaMA 3.1 8B en Q4_K_M occupe environ 5 Go se charge entièrement en GPU et atteint une vitesse d'inférence de 30 à 40 tokens par seconde soit un temps de réponse moyen de 10 à 20 secondes par prompt clinique.

b. Architecture technique du modèle 2 : Gemma3 27B Google DeepMind

Gemma3 27B est développé par Google DeepMind. Ses caractéristiques officielles, obtenues via la commande `ollama show gemma3:27b`, sont l'architecture `gemma3`, 27,4 milliards de paramètres, fenêtre de contexte de 131 072 tokens, dimension d'embedding de 5 376, quantization Q4_K_M, capacités multimodales (texte et vision), température native de 1,0, `top_k` de 64 et `top_p` de 0,95. La licence applicable est la Gemma Terms of Use (février 2024).

Sur le plan architectural, Gemma3 27B repose sur la même famille Transformer decoder-only que LLaMA, avec quelques spécificités. Sa dimension d'embedding de 5 376 est supérieure à celle de LLaMA 3.1 8B (4 096), ce qui reflète une plus grande capacité de représentation contextuelle. Gemma3 27B est le seul des trois modèles du projet à disposer de capacités multimodales : il peut traiter des images en plus du texte, une caractéristique qui pourrait être exploitée dans des phases ultérieures du projet pour analyser des documents médicaux numérisés.

Une particularité notable est sa température native fixée à 1,0 par Google DeepMind, valeur significativement plus élevée que celle des autres modèles. Sans contrôle explicite de ce paramètre dans les requêtes, Gemma3 produirait des réponses plus variables, ce qui biaiserait la comparaison inter-modèles. Dans les scripts du projet, la température est systématiquement imposée à 0,7 pour garantir des conditions homogènes entre les trois modèles. De même les paramètres `top_k` = 64 et `top_p` = 0,95 qui contrôlent la diversité de la sélection des tokens lors du décodage, sont des sources potentielles de variabilité si non maîtrisés.

Sur le plan matériel Gemma3 27B en Q4_K_M occupe environ 17 Go de VRAM. Sur la configuration utilisée (RX 7900 XTX, 24 Go) le modèle se charge entièrement en GPU avec une vitesse d'inférence de 10 à 15 tokens par seconde et un temps de réponse moyen de 20 à 40 secondes par prompt clinique.

c. Architecture technique du modèle 3 : Qwen 2.5 32B Alibaba Cloud

Qwen 2.5 32B est développé par Alibaba Cloud. Ses caractéristiques officielles, obtenues via `ollama show qwen2.5:32b`, sont l'architecture `qwen2`, 32,8 milliards de paramètres, fenêtre de contexte de 32 768 tokens, dimension d'embedding de 5 120, quantization Q4_K_M, capacités de completion et fonction calling. La licence applicable est l'Apache License Version 2.0, la plus permissive des trois modèles du projet.

Une différence architecturale importante distingue Qwen 2.5 32B des deux autres modèles : sa fenêtre de contexte est de 32 768 tokens, soit quatre fois moins que LLaMA 3.1 8B et Gemma3 27B (131 072 tokens chacun). Pour les prompts cliniques actuels du projet (200 à 500 tokens), cette limitation n'est pas contraignante. Elle le deviendrait en revanche si le protocole évoluait vers des cas incluant des historiques médicaux longs ou des résultats biologiques étendus.

Sur le plan matériel, Qwen 2.5 32B en Q4_K_M occupe environ 20 Go de VRAM, ce qui dépasse légèrement la capacité effective disponible sur la RX 7900 XTX. En pratique, le modèle déborde partiellement sur la RAM CPU (environ 33 % CPU, 67 % GPU), ce qui explique une vitesse d'inférence significativement réduite, de 3 à 5 tokens par seconde, et des temps de réponse allant de 44 secondes pour les prompts courts à 4 minutes 15 secondes pour les cas complexes (cas 009 sur hypoglycémies organiques, contexte narratif long). Ce dépassement a conduit à augmenter le timeout des requêtes HTTP de 300 à 600 secondes pour éviter les interruptions prématurées.

Justification de nos choix de modèle.

LLaMA 3.1 8B est le modèle le plus étudié dans la littérature sur l'évaluation des LLM en médecine. Ses poids sont publics, ce qui assure la reproductibilité. Avec 8 milliards de paramètres, il offre un bon compromis. Les variantes plus grandes seraient plus performantes mais impossibles à faire tourner localement. Un modèle plus petit aurait été trop limité pour des cas cliniques complexes. Il constitue la référence du projet.

Gemma3 27B occupe une position intermédiaire. Il tient dans la VRAM disponible, contrairement à Qwen 2.5 32B. Sa capacité multimodale ouvre des perspectives intéressantes pour de futures extensions du protocole. Son rôle est de tester si davantage de paramètres améliore la stabilité face aux reformulations.

Qwen 2.5 32B représente le plafond de performance de la comparaison. Avec 32,8 milliards de paramètres, il est reconnu pour son raisonnement complexe et sa précision sur des tâches scientifiques. Sa licence Apache 2.0 est la plus permissive des trois. Il joue le rôle du modèle haute performance dans le projet.

Tableau 1 : Récapitulatif des 3 modèles

Caractéristique	LLaMA 3.1 8B	Gemma3 27B	Qwen 2.5 32B
Développeur	Meta AI	Google DeepMind	Alibaba Cloud
Paramètres	8,0 milliards	27,4 milliards	32,8 milliards
Fenêtre de contexte	131 072 tokens	131 072 tokens	32 768 tokens
Embedding	4 096 dimensions	5 376 dimensions	5 120 dimensions
Quantization	Q4_K_M	Q4_K_M	Q4_K_M
VRAM utilisée	Environ 5 Go	Environ 17 Go	Environ 20 Go
Chargement GPU	100 % GPU	100 % GPU	~67 % GPU / 33 % CPU
Vitesse d'inférence	30–40 tok/s	10–15 tok/s	3–5 tok/s
Temps de réponse moyen	10–20 secondes	20–40 secondes	1–4 minutes
Multimodal	Non	Oui (vision)	Non
Function calling	Oui	Non	Oui
Temperature native	Non spécifiée	1,0	Non spécifiée
Licence	LLaMA 3.1 Community	Gemma Terms of Use	Apache 2.0
Rôle dans le projet	Modèle de référence	Modèle intermédiaire	Modèle haute performance

Résumé exécutif de la méthodologie. Le protocole vise à évaluer l'impact de la reformulation du prompt sur la qualité, la sécurité et la stabilité des réponses de trois modèles de langage : LLaMA 3.1 8B Instruct, Gemma3 27B et Qwen 2.5 32B. Ces modèles ont été déployés localement via Ollama sur une configuration AMD RX 7900 XTX (24 Go VRAM) dans un contexte d'aide à l'interprétation médicale. Le protocole repose sur 15 cas cliniques synthétiques issus de collègues d'enseignants en endocrinologie chacun décliné en trois types de reformulation (narratif, condensé, reformulé) et répété trois fois. Il y a donc 135 exécutions par modèle. Deux configurations de température sont utilisées selon l'objectif. Une température = 0 pour les tests isolant l'effet de la reformulation et une température = 0.7 pour les tests de stabilité avec répétitions. Toutes les exécutions sont tracées et journalisées. Les réponses sont évaluées par un expert à l'aide via une grille d'évaluation couvrant six dimensions : fidélité (vis-à-vis des éléments attendus), sécurité clinique (présence de recommandation dangereuse), hallucinations (présences d'informations inventées), stabilité inter-reformulation et confiance déclarée. L'analyse statistique s'organise en trois niveaux complémentaires. Tout d'abord, une analyse descriptive des distributions et de la stabilité intra reformulation. Ont fait suite, des tests d'inférence adaptés à la structure des mesures (Friedman, Cochran Q, Spearman). Enfin, des métriques automatiques de qualité des réponses seront étudiées (BERTScore, ECE). L'ensemble vise à répondre à trois principales questions : **le type de reformulation influence-t-il significativement la qualité des réponses ? Un modèle est-il supérieur aux autres ? La confiance déclarée par les modèles reflète-t-elle leur exactitude réelle ?** Les résultats attendus selon la littérature une instabilité inter-reformulation mesurable et une surconfiance systématique des modèles indépendants de la qualité effective des réponses.

1. Objectifs expérimentaux et hypothèses

a. Objectifs expérimentaux mesurables

Ce projet vise un usage d'aide au diagnostic via l'interprétation d'analyses et de contexte pour donner des recommandations. Pour rappel, il n'a en aucun cas pour vocation à générer une décision clinique arrêtée. Conformément aux cadres de gestion des risques nous définissons des objectifs expérimentaux mesurables et traçables. Tous nos objectifs sont associés à des métriques et à des critères d'acceptabilité.

Objectif principal. Évaluer de manière quantitative et qualitative **l'impact de la reformulation du prompt** sur la qualité, la sécurité, la stabilité et la fiabilité des réponses produites par des grand modèle de langage (LLaMA 3.1 8B Instruct, Gemma3 27b, qwen2.5:32b) dans un contexte d'aide à l'interprétation de situation médicale.

Les objectifs secondaires sont les suivants :

- **OS1. EXACTITUDE** (au sens de fidélité): Mesurer la capacité du LLM à faire une interprétation cohérente avec les données fournies pour répondre à la demande.
- **OS2. SECURITE CLINIQUE** : Quantifier la proportion de réponses contenant des recommandations potentiellement dangereuses, inadaptées ou insuffisamment nuancées.
- **OS3. STABILITE INTER-REFORMULATION** : Quantifier la variabilité des réponses pour un même cas clinique lorsque la formulation du prompt est modifiée (type de reformulation et ordre des informations).
- **OS4. HALLUCINATIONS** : Estimer la fréquence d'informations non justifiées par les données fournies dans le cas clinique.
- **OS5. CONFIANCE ET CALIBRATION** : Évaluer l'adéquation entre le niveau de confiance déclaré par le modèle et la qualité réelle de sa réponse.
- **OS6. COMPARAISON INTER-MODELES** : Identifier les différences de comportement entre modèles distincts soumis aux mêmes cas et reformulations.

b. Hypothèses de travail (issues des objectifs)

- **H1.** (OS3)
Un même cas clinique génère des réponses qualitativement différentes selon le type de reformulation du prompt.
- **H2.** (OS1, OS4)
Certaines reformulations (notamment condensées ou directes) augmentent le risque d'omission d'éléments essentiels ou d'hallucinations.
- **H3.** (OS2, OS5)
Les réponses les plus longues ou les plus affirmatives ne sont pas nécessairement les plus exactes ni les plus sûres.
- **H4.** (OS5)
Le niveau de confiance déclaré par le modèle est peu corrélé à la qualité réelle de la réponse évaluée par l'expert.
- **H5.** (OS3, implication clinique)
La variabilité inter-reformulation est suffisamment importante pour justifier une standardisation des pratiques d'interrogation en contexte clinique.

Le OS6 correspondent à la comparaison des évaluations entre modèles.

2. Données et constitution du jeu d'étude

a. Nature et origine des données

Le protocole est conçu pour fonctionner avec deux types de données. Les **DONNEES REELLES** qui sont les résultats biologiques issus d'un protocole de recherche ou d'un établissement de santé, préalablement anonymisés ou pseudonymisés (l'objectif étant d'être au plus proche de la réalité que représenterai l'utilisation d'un LLM de ce type). **Les DONNEES SYNTHETIQUES** qui sont les cas simulés construits et validés par un expert, reproduisant des profils biologiques réalistes sans données personnelles.

Dans notre cas, les données utilisées sont **SYNTHETIQUE** avec pour objectif d'évaluer le modèle (phase d'inférence), et non pour l'entraîner. Nous avons donc décidé d'utiliser le Collège des enseignants de médecine intensive-réanimation (2023) et le Collège des enseignants d'endocrinologie, diabète et maladies métaboliques (2022).

b. Variables minimales par cas

Chaque cas doit être structuré pour permettre des prompts strictement comparables. Le jeu de données doit contenir, au minimum :

- **Identifiant** : pseudonyme, il est important qu'il soit sans lien direct avec une identité. Dans notre cas, il s'agit de l'identifiant du prompt.
- **Âge**
- **Sexe** : (homme ou femme)
- **Contexte clinique minimal** : symptômes principaux, antécédents pertinents.
- **Intervalles de référence** : si disponibles (sinon non spécifiés et l'expert tranche les règles d'interprétation attendues).
- **Éléments-clés attendus** : issus des collèges et vérifié par l'expert.

c. Critères d'inclusion et d'exclusion

Afin de garantir la qualité de l'évaluation, certains critères sont définis. Il sera INCLU uniquement les cas contenant un panel biologique suffisant pour permettre une interprétation et les patients seront adultes (> 18 ans). Il sera EXCLU les données incohérentes (unités incorrectes, valeurs aberrantes non exploitables), les cas incomplets empêchant toute interprétation (ex : variable essentielle absente).

d. Typologie des reformulations

Trois types de reformulation sont testés pour chaque cas clinique. Ces types ont été définis pour représenter des modalités d'interrogation réalistes et diversifiées, telles qu'elles pourraient être observées dans une pratique médicale réelle :

Type	Libellé	Description	Caractéristiques principales
1	Narratif (1-Narratif)	Présentation clinique complète sous forme de récit médical	Contexte riche, formulation fluide, ordre logique, proche d'un compte-rendu médical
2	Condensé (2-Condense)	Informations essentielles présentées de façon synthétique	Formulation courte, style télégraphique, données biologiques listées sans contexte narratif
3	Reformulé (3-Reformule)	Même contenu que le prompt narratif, reformulé avec une demande différente	Variation de la consigne, de l'ordre des éléments ou du niveau de directivité

L'identifiant de prompt suit la nomenclature AAA.X, où AAA est le numéro du cas (001-015) et X est le type de reformulation (1, 2 ou 3). Chaque combinaison est répétée trois fois (répétitions 1, 2, 3), soit 9 exécutions par cas et 135 au total.

3. Déploiement technique et sécurité

a. Infrastructure de déploiement

Le déploiement local se fait sur Ollama (un moteur d'inférence open source qui charge les modèles LLM en mémoire et expose une API REST locale sur <http://localhost:11434>). Les trois modèles sont téléchargés et exécutés sur une configuration matérielle AMD RX 7900 XTX (24 Go de VRAM) sous Windows. Cette architecture garantit la confidentialité des données et aucune information ne transitant vers des serveurs externes ce qui facilite la traçabilité des expérimentations.

LLaMA 3.1 8B et Gemma3 27B se chargent entièrement en GPU. Qwen 2.5 32B déborde partiellement sur la RAM CPU en raison de son poids d'environ 20 Go ce qui nécessite un timeout étendu à 600 secondes pour les requêtes.

b. Configuration d'inférence et reproductibilité

Deux configurations de temperature sont utilisées selon l'objectif. Il a été paramétré une temperature de 0 (décodage déterministe) pour les tests isolant l'effet de la reformulation comme unique variable expérimentale. Cela signifie que pour un même prompt, le modèle produit toujours la même réponse. Et une température de 0.7 pour les tests de stabilité avec 3 répétitions par prompt permettant d'observer si les réponses divergent malgré une légère variabilité stochastique.

Le paramètre num_gpu est fixé 99 force le chargement maximal des couches en VRAM. La fenêtre de contexte num_ctx est fixée à 4 096 tokens largement suffisante pour les prompts cliniques du projet (200 à 500 tokens). Ces paramètres sont maintenus constants et enregistrés pour chaque session.

La temperature native du modèle Gemma3 27B est de 1.0 dans ses paramètres par défaut. Cela signifie que sans spécification explicite dans chaque requête HTTP, Gemma3 produirait des réponses significativement plus variables que LLaMA et Qwen biaisant la comparaison inter-modèles. La temperature est par conséquent systématiquement imposée à la valeur cible dans chaque appel API.

c. Sécurité et conformité RGPD

Dans le cas d'une utilisation de données réelles, celles-ci sont considérées comme des données de santé et soumises au RGPD (Article 9). Ce cadre réglementaire impose notamment la pseudonymisation ou

l'anonymisation, la minimisation des données, la limitation de la durée de conservation, la sécurisation des systèmes et la responsabilité du traitement

Dans ce projet, et avec une vision long terme où nos recherches continueraient, l'anonymisation des données avant traitement, l'absence de données identifiantes dans les prompts, la tenue d'un registre interne des traitements, la sensibilisation des membres du projet et validation par un référent (tuteur académique) ainsi qu'une veille réglementaire régulière sont des mesures déjà mise en place.

Ces pratiques sont cohérentes avec les recommandations de l'OMS (WHO), qui considère l'IA en santé comme une technologie à haut enjeu nécessitant des mécanismes de gouvernance et de supervision renforcés.

4. Grille d'évaluation multicritère

La grille d'évaluation constitue l'outil principal de la méthodologique du projet. Chaque modèle est soumis à la même grille d'évaluation. Elle permet une analyse structurée, reproductible et expert-validée des réponses du modèle. Elle est remplie par le Dr Jean Canarelli et l'interne Chjara-Maria Tomasi, pour chaque réponse générée. L'objectif de cette grille est de traduire en variables quantifiables et comparables pour faire des conclusions. Chaque composante de la grille correspond à un élément du LLM que l'on souhaite évaluer en contexte médical et renvoie à un ou plusieurs objectifs expérimentaux du projet.

La première famille de variables concerne l'exactitude de l'interprétation clinique produite par le modèle de LLM évalué. Pour chaque cas les éléments-clés attendus sont issus des réponses des annales utilisées notée « N_ref », la réponse devrait impérativement mentionner pour être considérée comme correcte au regard des recommandations médicales. Par conséquent, N_correct désigne le nombre de ces éléments effectivement présents et correctement évoqués dans la réponse du modèle et N_omis correspond à ceux qui auraient dû figurer mais sont absents. Le score d'exactitude S_exact est calculé comme le rapport N_correct sur N_ref constituant un taux compris entre 0 et 1 où une valeur proche de 1 indique que le modèle a couvert l'ensemble des éléments attendus. Une valeur faible de S_exact signifiant un N_omis élevé signale non pas une réponse fausse, mais une réponse incomplète ce qui dans un contexte d'aide au diagnostic peut être tout aussi problématique. Il est considéré qu'un élément manquant peut conduire à une prise en charge inadaptée.

À l'opposé de l'omission le modèle peut produire des informations qui ne sont pas justifiées par les données fournies dans le cas clinique, elles sont comptabilisées dans les N_ajout. La variable binaire info_inventée (codée 0 pour absent et 1 pour présent) indique si au moins une de ces informations non justifiées est présente dans la réponse. N_ajout et info_inventée sont les indicateurs des hallucinations card elles permettent de distinguer une réponse incomplète d'une réponse qui enrichit son contenu avec des éléments inventés. Ce phénomène est particulièrement risqué en médecine car une information ajoutée par le modèle peut sembler plausible sur le plan rhétorique et orienterait le clinicien vers un diagnostic erroné.

La variable reco_dangereuse est également une variable binaire (0 = non, 1 = oui) qui indique si la réponse du modèle contient une recommandation potentiellement dangereuse pour le patient tel qu'une contre-indication ignorée, un traitement inadapté au profil, ou encore une absence de signalement d'une urgence clinique. C'est la variable la plus directement liée à la sécurité des patients. Contrairement à une omission ou à une imprécision, une recommandation dangereuse constitue un risque actif car si un clinicien la suit sans recul critique elle peut directement affecter la prise en charge thérapeutique en mettant en danger le patient. Cette variable est évaluée indépendamment du score d'exactitude car une réponse peut être incomplète sans être dangereuse ou au contraire contenir des éléments corrects tout en incluant une recommandation problématique, nécessitant d'être comptabilisée séparant.

La grille recueille également le score de confiance déclaré par le modèle dans sa réponse (exprimé sur une échelle de 0 à 100). Ce score est extrait automatiquement lorsque le modèle le formalise explicitement dans sa réponse.

La longueur de la réponse (exprimée en nombre de mots) est une métrique descriptive qui permet d'analyser des comportements indirects du modèle et voir la corrélation entre reformulation et réponse. Même si une réponse longue n'est pas nécessairement plus exacte, celle-ci peut tout de même simplement refléter une tendance du modèle à générer du contenu plus long pour compenser une incertitude, à répéter

des éléments déjà mentionnés ou à ajouter des informations non demandées qui font mécaniquement augmenter N_ajout et une réponse très courte peut être le signe d'une omission massive. La longueur est donc une variable de contrôle qui croisée avec S_exact et N_ajout permet de distinguer les réponses denses et pertinentes des réponses longues mais creuses. Elle est aussi utile pour analyser les différences de comportement entre les types de reformulation et évaluer si la formulation condensée tend à produire des réponses plus courtes, voir à justifier le nombre de N_omis par le type de reformulation.

Tableau 2 : Tableau récapitulatif des variables de la grille d'évaluation

Section	Variable	Type	Description
Identification	case_id	Texte	Identifiant du cas clinique (001 à 015)
Identification	prompt_id	Texte	Identifiant du prompt selon la nomenclature AAA.X (ex. 001.2 = cas 001, reformulation condensée)
Identification	Type de reformulation	Catégorielle (3 modalités)	Type de reformulation appliquée : 1-Narratif, 2-Condensé, 3-Reformulé
Identification	Répétition	Entier (1, 2 ou 3)	Numéro de la répétition pour un même prompt (permet de vérifier la stabilité stochastique à température = 0)
Référence clinique	Éléments-clés attendus	Texte libre	Liste des éléments biologiques, diagnostics ou orientations que la réponse doit impérativement mentionner, définis en amont par l'expert clinicien pour chaque cas
Référence clinique	N_ref	Entier ≥ 1	Nombre total d'éléments-clés attendus définis par l'expert pour ce cas clinique
Exactitude	N_correct	Entier ≥ 0	Nombre d'éléments-clés attendus effectivement présents et correctement évoqués dans la réponse du modèle
Exactitude	N_omis	Entier ≥ 0	Nombre d'éléments-clés attendus absents de la réponse ($N_{ref} - N_{correct}$)
Exactitude	N_ajout	Entier ≥ 0	Nombre d'éléments introduits par le modèle sans justification dans le cas clinique fourni (informations non demandées ou non déductibles du prompt)
Exactitude	Score d'exactitude (S_exact)	Continu [0 ; 1]	Taux de rappel clinique calculé : $N_{correct} / N_{ref}$. <i>Une valeur proche de 1 indique une couverture complète des éléments attendus</i>
Sécurité	Reco. dangereuse	Binaire (0 / 1)	0 = la réponse ne contient aucune recommandation potentiellement dangereuse. 1 = la réponse contient au moins une recommandation inadaptée, contre-indiquée ou susceptible d'induire une prise en charge incorrecte.
Hallucination	Info. inventée	Binaire (0 / 1)	0 = toutes les affirmations de la réponse sont justifiées par les données du cas clinique. 1 = la réponse contient au moins une information non justifiable par le contexte fourni dans le prompt.
Confiance	Confiance déclarée	Entier [0 ; 100]	Score de confiance formulé par le modèle dans sa réponse, exprimé sur 100.

5. Analyse statistique

L'analyse statistique correspond à la méthode et aux outils utilisés pour utiliser les éléments de la grille d'évaluation afin de pouvoir les interpréter. L'objectif est de rendre les évaluations issues de la grille en résultats répétable, interprétables, comparables et défendables scientifiquement. Cette section est organisée en trois niveaux correspondant à trois couches d'analyse complémentaires allant de la description des données, à la comparaison entre groupes par des tests d'inférence et l'évaluation automatique de la qualité des réponses par des métriques spécialisées.

a. Niveau 1 : Analyse descriptive

L'analyse descriptive est la première étape de tout traitement statistique, grâce à elle, il est possible de caractériser les distributions des scores et d'identifier les tendances générales. Elle ne permet pas de conclure à une différence significative mais peut orienter l'interprétation et prépare les analyses ultérieures.

Pour chaque **VARIABLE QUANTITATIVE CONTINUE** tel que score d'exactitude biologique ($S_{\text{exact}} = N_{\text{correct}} / N_{\text{ref}}$), la confiance déclarée (0–100) et la longueur de la réponse en mots dans notre cas, plusieurs statistiques descriptives ont été calculées séparément pour chaque type de reformulation (narratif, condensé, reformulé) pour chaque modèle, voir pour chaque répétition. Les plus pertinentes dans le cadre de ce projet sont les moyenne arithmétique (tendance centrale mais sensible aux valeurs extrêmes), la médiane (plus robuste que la moyenne si distributions asymétriques), l'écart-type (signale une hétérogénéité importante entre cas ou entre répétitions). Dans le cadre de nos calculs statistiques seront calculées sur les 135 lignes de chaque modèle puis ventilées par type de reformulation (45 lignes par groupe) pour observer si la formulation du prompt influe sur le niveau moyen et la dispersion des scores. Un score moyen d'exactitude élevé (c'est-à-dire proche de 1) sur l'ensemble des cas indiquera une bonne couverture des éléments cliniques attendus. En opposition, un écart-type élevé entre répétitions d'un même cas, à formulation identique, révélera une instabilité stochastique problématique pour un usage clinique.

Pour chaque **VARIABLE BINAIRE** tel que reco_dangereuse (0/1) et info_inventee (0/1), la statistique descriptive principale est le pourcentage calculé par type de reformulation par modèle. Ces taux sont directement interprétables cliniquement car si 20 % des réponses d'un modèle contiennent une recommandation potentiellement dangereuse cela signifie qu'une réponse sur cinq présente un risque pour le patient. L'acceptabilité ou l'inacceptabilité d'un modèle selon ce pourcentage est ensuite à déterminer en lien avec la confiance accordée par les utilisateurs. Un autre exemple serait que pour un taux d'hallucination élevé sur la reformulation condensée par rapport à la formulation narrative indiquerait que la réduction du contexte fourni fragilise la fiabilité du modèle.

Il sera également calculé la stabilité intra-cas afin de caractériser l'instabilité inter-reformulation au niveau du cas plutôt que du groupe en comparant les répétitions des reformulations.

b. Niveau 2 : Tests d'inférences statistiques

Pour déterminer si les différences observées entre groupes reflètent un effet réel ou relèvent simplement du hasard, nous avons eu recours à des tests d'inférence statistique. Leur sélection a reposé sur trois critères. Le premier critère est la nature des variables analysées (continues ou binaires), le deuxième est la structure des données (les mêmes cas cliniques étant soumis à plusieurs conditions), et le troisième est la taille réduite de l'échantillon ($N = 15$ cas). Il a été décidé d'effectuer trois tests à ce niveau d'analyse.

CORRELATION DE SPEARMAN (annexeX)

Objectif. Ce test vise à répondre à l'hypothèse H4 soit **le niveau de confiance qu'un modèle exprime dans ses réponses est-il réellement lié à leur qualité clinique ?**

Pourquoi ce test. Nous avons retenu la corrélation de Spearman car elle opère sur les rangs des valeurs plutôt que sur les valeurs brutes, ce qui la rend peu sensible aux distributions asymétriques et aux valeurs extrêmes, deux caractéristiques probables avec seulement 15 cas.

Ce que fait concrètement le test. Concrètement, chaque réponse est caractérisée par deux valeurs : le score de confiance que le modèle s'attribue lui-même (par exemple 85/100) et le score d'exactitude établi par l'expert clinicien ($S_{\text{exact}} = N_{\text{correct}} / N_{\text{ref}}$). Le test évalue dans quelle mesure les réponses les plus confiantes sont aussi les plus exactes.

Interprétation. Un ρ proche de 1 traduirait une bonne calibration c'est-à-dire que le modèle saurait en quelque sorte quand il a raison et quand il doute. Un ρ proche de 0 signifierait à l'inverse que la confiance affichée est déconnectée de la qualité réelle correspondant au scénario le plus probable. Par exemple si les modèles ont tendance à s'attribuer des scores proches de 80/100 quelle que soit la pertinence de leur réponse. Le cas le plus inquiétant serait un ρ négatif où le modèle serait paradoxalement plus affirmatif dans ses erreurs que dans ses réponses correctes.

TEST DE FRIEDMAN (annexeX)

Objectif. Ce test répond à l'hypothèse H1 soit la façon dont un cas clinique est formulé influence-t-elle les performances du modèle ?

Pourquoi ce test. Il s'agit d'un équivalent non paramétrique de l'ANOVA à mesures répétées, il a été préféré parce que la normalité des distributions ne peut pas être supposée avec un aussi petit échantillon et que les scores d'exactitude (bornés entre 0 et 1) génèrent fréquemment des distributions asymétriques.

Ce que fait concrètement le test. Le principe est que pour chaque cas clinique les scores obtenus sous les trois formulations sont classés par ordre croissant. Le test compare ensuite les rangs moyens obtenus par chaque type de reformulation sur l'ensemble des cas, afin de déterminer si ces écarts sont significatifs.

Interprétation. Un résultat $p < 0.05$ s'interpréterait comme une confirmation que le modèle est sensible à la formulation du prompt. Dans le cas contraire cela suggérerait une certaine robustesse aux variations linguistiques. Des analyses post-hoc de Wilcoxon avec correction de Bonferroni permettent d'identifier précisément quelles paires de reformulations sont à l'origine des différences observées.

TEST Q DE COCHRAN (Annexe X)

Objectif. Tester si les taux de recommandations dangereuses (reco_dangereuse) et d'hallucinations (info_inventee) varient selon le type de reformulation.

Pourquoi ce test. Le Q de Cochran est l'extension du test de McNemar à K conditions (ici $K = 3$ reformulations). Il est conçu spécifiquement pour les variables binaires mesurées sur les mêmes individus : pour chaque cas, on dispose de trois observations binaires, une par reformulation, indiquant si la réponse était dangereuse ou hallucinée.

Ce que fait concrètement le test. Le test regarde combien de cas changent de statut entre les conditions. Si un cas noté 0 en narratif mais 1 en condensé contribue à signaler une instabilité. Il compare les proportions de 1 entre les trois reformulations en tenant compte de la structure appariée des données. L'hypothèse nulle est que cette proportion est identique dans les trois conditions.

Interprétation. Si $p < 0.05$ signifie que la formulation du prompt influence significativement la probabilité qu'une réponse soit dangereuse ou hallucinée. C'est le résultat cliniquement le plus préoccupant car un même cas pourrait être traité de manière sûre ou dangereuse selon la façon dont le médecin formule sa question. Des post-hoc par McNemar identifient quelles paires de reformulations sont responsables de l'effet. Si $p \geq 0.05$, les taux restent stables selon la reformulation, ce qui constitue un signal positif de robustesse sur ce critère de sécurité. Pour les comparaisons binaires inter-modèles sur les mêmes cas, le test exact de Fisher est préféré au chi-deux classique, les effectifs attendus dans certaines cellules pouvant être inférieurs à 5 avec $N = 15$ cas.

Tableaux 3 : Récapitulatif des tests d'inférences par type de donnée.

Variable	Test
S_exact	Friedman
Confiance déclarée	Friedman
Reco dangereuse (0/1)	Cochran Q
Info inventée (0/1)	Cochran Q
Confiance vs S_exact	Spearman

c. Niveau 3 : Métriques de qualité des réponses

Au-delà de l'évaluation humaine experte, des métriques automatiques permettent de quantifier des dimensions supplémentaires de la qualité des réponses, similarité sémantique entre reformulations et

calibration de la confiance, sans annotation manuelle supplémentaire. Ces métriques complètent la grille d'évaluation sans la remplacer. Elles sont présentées par ordre croissant de complexité.

BERTSCORE (annexe x)

Principe. BERTScore (Zhang et al., 2020) encode chaque réponse en représentations vectorielles contextuelles à l'aide d'un modèle de type BERT, puis calcule la similarité cosinus entre les tokens de la réponse candidate et ceux de la réponse de référence. Contrairement à des métriques lexicales comme ROUGE ou BLEU, BERTScore capture la similarité sémantique indépendamment des formulations exactes. Cela est particulièrement adapté au contexte médical, où des termes synonymes tel que « hypothyroïdie » et « insuffisance thyroïdienne » expriment le même concept clinique sans partager aucun mot en commun.

Usage concret dans ce projet. BERTScore est calculé de deux façons complémentaires. En tant que mesure de stabilité où pour chaque cas clinique, les réponses produites sous les trois reformulations sont comparées deux à deux (narratif vs condensé, narratif vs reformulé, condensé vs reformulé) ce qui produit trois scores F1 par cas. Une moyenne des score F1 élevé indique que le modèle a produit des réponses sémantiquement proches malgré la variation de formulation, signifiant une bonne robustesse. En tant que mesure de qualité, les réponses sont comparées à la réponse de référence définie par l'expert en fournissant un indicateur automatique de proximité avec le contenu attendu.

Interprétation. Un score F1 élevé entre reformulations confirme la cohérence sémantique du modèle face aux variations de prompt. Un score faible sur certains cas identifie les situations sensibles où la formulation modifie substantiellement le contenu produit. Une divergence entre BERTScore et S_exact (correspondant par exemple à un score sémantique élevé mais fidélité clinique faible), signalera le problème des hallucinations fluides soit que les réponses sont rhétoriquement plausibles mais cliniquement inexacts.

METRIQUES DE CALIBRATION (annexe x)

Principe. L'ECE mesure l'écart moyen entre la confiance déclarée par le modèle et sa précision empirique réelle. Les réponses sont regroupées par intervalles de confiance de 20 points (0-20, 20-40, 40-60, 60-80, 80-100). Pour chaque intervalle, la précision réelle proportion de réponses correctes au sens de l'expert, est comparée à la confiance moyenne déclarée dans cet intervalle. L'ECE est la moyenne pondérée des écarts absolus entre ces deux grandeurs sur l'ensemble des intervalles.

Usage concret dans ce projet. Si toutes les réponses dans l'intervalle 80-100 ont un score d'exactitude expert moyen de 0,55, le modèle est confiant à 80-100 % pour des réponses correctes seulement à 55 % (illustration directe de la surconfiance). Le reliability Diagram visualise ce phénomène avec la confiance déclarée est placée en abscisse et la précision réelle en ordonnée. Une calibration parfaite correspond à la diagonale $y = x$. Tout point situé en dessous de cette diagonale indique une surconfiance (confiance > précision réelle) et tout point au-dessus indique une sous-confiance.

Interprétation. Un ECE proche de 0 indique une bonne calibration avec le modèle qui exprime une confiance proportionnelle à sa justesse réelle, propriété indispensable pour un usage clinique fiable. Un ECE élevé combiné à une confiance systématiquement surestimée correspond au résultat attendu au regard des premières observations avec des scores quasi-systématiquement à 80/100 quelle que soit la qualité de la réponse. Cela confirmerait le phénomène de surconfiance documenté dans la littérature et constituerait un argument fort contre l'utilisation directe de ces scores comme indicateur de fiabilité.

Avec $N = 15$ cas, les intervalles de calibration seront nécessairement peu peuplés donc ce résultat est présenté à titre indicatif et interprétatif plutôt que comme une estimation statistiquement précise.

RESULTATS

Résumé exécutif des résultats. Les résultats disponibles couvrent les métriques automatiques pour les trois modèles et les analyses de grille experte pour Qwen 2.5 32B uniquement. Les évaluations de LLaMA 3.1 8B et Gemma3 27B étant en cours de finalisation par les experts. Sur les métriques automatiques, il est noté la verbosité des modèles constitue une caractéristique intrinsèque stable. Gemma3 27B produit les réponses les plus longues (250-370 tokens) suivi de Qwen 2.5 32B (180–250 tokens) et LLaMA 3.1 8B (100-170 tokens), indépendamment du type de reformulation. Les scores de confiance auto-déclarés sont élevés et stables pour les trois modèles constituant un premier signal de surconfiance systématique. Sur les résultats de grille pour Qwen 2.5 32B, trois constats principaux se distinguent. La reformulation influence significativement l'exactitude clinique (Friedman : ($\chi^2(2) = 9.82$, $p = 0.007$), avec un effet concentré sur la paire narratif vs reformulé (avec $p < 0.001$ après correction de Bonferroni), le prompt narratif obtenant les meilleures performances. Aucune recommandation dangereuse n'a été produite pour ce modèle et le taux d'hallucinations ne varie pas selon la reformulation ($p = 0.368$), cela indique que la sensibilité au prompt affecte la globalité des réponses plus que leur sécurité. La calibration est jugée insuffisante avec une corrélation confiance/fidélité faible ($\rho = 0.233$) et une ECE élevée (0.359). Concrètement des réponses produites à 85-90 % de confiance déclaré n'atteignent qu'une exactitude réelle de 50%. Sur le BERTScore les trois modèles présentent une qualité sémantique modérée face aux éléments attendus ($F1 = 0.57$) mais une bonne stabilité inter-répétitions et inter-reformulations, Gemma3 27B se distinguant comme le modèle le plus stable.

Deux conclusions transversales se dégagent : **la reformulation affecte significativement la qualité des réponses sans modifier le niveau de confiance affiché**, et **la confiance auto-déclarée ne constitue pas un indicateur fiable de l'exactitude réelle** étant des propriétés critiques pour tout usage responsable en contexte médical.

Cette section présente les résultats quantitatifs obtenus lors de la phase expérimentale du projet LLMQ, son organisation est conforme à celle présentée dans la partie *Analyse Statistique* de la méthodologie. Les trois grands modèles de langage évalués ont été **LLaMA 3.1 8B Instruct**, **Gemma3 27b**, **Qwen2.5 32b**.

Étant donnée la charge de travail importante nécessaire à la complétion de notre grille d'évaluation par les experts, les résultats présentés ci-après correspondent aux premières évaluations déjà réalisées. L'ensemble des autres modèles prévus dans l'étude pourra être évalué ultérieurement, au fur et à mesure du retour des experts et de la finalisation des analyses associées.

1. Niveau 1 : Analyse descriptive

La Figure 3 présente la longueur moyenne (en nombre de tokens) des réponses produites par les trois modèles évalués en fonction du type de prompt (Narratif, Condensé, Reformulé) et de la version de reformulation (1, 2, 3).

Une différence marquée s'observe entre les modèles. Gemma3 27b génère systématiquement les réponses les plus longues avec des moyennes oscillantes entre 250 et 370 tokens selon les conditions quel que soit le type de prompt ou la reformulation. Qwen2.5:32b se positionne à un niveau intermédiaire, avec des valeurs comprises entre 180 et 250 tokens, tandis que LLaMA 3.1 8B Instruct produit les réponses les plus courtes, généralement entre 100 et 170 tokens. Cette tendance est cohérente et stable à travers l'ensemble des conditions testées, ce qui suggère que la verbosité des modèles constitue une caractéristique intrinsèque davantage qu'une réponse aux variations de prompt.

Par ailleurs, le type de prompt Reformulé (3-Reformulé) tend à produire des réponses légèrement plus courtes pour tous les modèles comparativement aux types Narratif et Condensé, bien que cet effet reste modeste.




Figure 3 - Longueur moyenne des réponses générées (en tokens) selon le modèle, le type de prompt et la version de reformulation

La Figure 4 présente les scores de confiance moyens exprimés par chaque modèle dans ses réponses sur une échelle de 0 à 100 en fonction des mêmes conditions expérimentales. Les scores de confiance se révèlent globalement élevés pour l'ensemble des modèles, avec des moyennes comprises entre 79 et 91. Gemma3 27b affiche les scores les plus élevés, dépassant 90 dans plusieurs conditions, notamment pour le type de prompt Reformulé. Qwen2.5:32b présente des scores légèrement inférieurs mais stables autour de 86 à 88. LLaMA 3.1 8B Instruct, qui a des réponses plus courtes, exprime tout de même des scores de confiance en moyenne élevé, compris entre 79 et 82.

Il est important de noter que ces scores de confiance sont auto-déclarés par les modèles eux-mêmes et ne reflètent pas nécessairement la qualité réelle des réponses. Cette observation rejoint les travaux de la littérature soulignant le problème de calibration des LLM qui tendent à afficher une confiance élevée même en présence d'erreurs ou d'imprécisions cliniques (mise en avant lorsqu'elle est corrélée au score de fidélité).




Figure 4 - Score de confiance moyen auto-déclaré (sur 100) selon le modèle, le type de prompt et la version de reformulation

Modèle LLaMA3.1 8B Instruct

Les analyses présentées dans cette partie seront réalisées une fois l'ensemble des résultats d'évaluation par les experts reçus et consolidés.

Modèle Gemma3 27b

Les analyses présentées dans cette partie seront réalisées une fois l'ensemble des résultats d'évaluation par les experts reçus et consolidés.

Modèle Qwen2.5:32b

Le modèle Qwen2.5:32b présente 0% de recommandation dangereuse et 0% d'information inventées. La Figure 5 présente la répartition du score d'exactitude moyen obtenu par le modèle Qwen2.5:32b selon les trois types de prompts utilisés. Le type de prompt Narratif obtient le score d'exactitude le plus élevé, représentant 62 % de la moyenne globale, ce qui suggère que ce format, plus riche en informations contextuelles, favorise des réponses davantage alignées avec les attendus cliniques. Le prompt Condensé arrive en seconde position avec 48 %, tandis que le prompt Reformulé n'atteint que 42 %. Ces résultats indiquent que la réduction ou la modification de la formulation du contexte clinique tend à dégrader la qualité des réponses du modèle en termes d'exactitude, soulignant ainsi sa sensibilité au format et à la complétude de l'information fournie en entrée.




Figure 5 - Répartition du score de fidélité moyen selon le type de prompt pour le modèle Qwen2.5:32b

La Figure 6 détaille pour le modèle Qwen2.5:32b les moyennes des quatre indicateurs d'erreur de contenu qui sont les ajouts non pertinents (N_ajout), les omissions d'éléments attendus (N_omis), les éléments corrects (N_correct) et les éléments de référence attendus (N_ref), selon le type de prompt. Plusieurs constats émergent. Le nombre moyen d'ajouts (N_ajout) est systématiquement élevé pour tous les types de prompts, avec des valeurs proches de 3.7 à 3.8 pour les prompts Narratif et Condensé, et légèrement plus faible (environ 2.3) pour le prompt Reformulé. Cela témoigne d'une tendance du modèle à enrichir ses réponses d'informations non sollicitées, comportement caractéristique de l'hallucination additive dans les LLM. Les omissions (N_omis) restent relativement contenues, autour de 1 à 1.4, indiquant que le modèle parvient généralement à inclure les éléments attendus, même si certains restent absents. Le nombre d'éléments corrects (N_correct) demeure faible, entre 1 et 1.3, rapporté au nombre de références attendues (N_ref) fixé à environ 2.3, ce qui révèle un taux de couverture des éléments cliniques essentiels limité. Ces résultats confirment que si le modèle produit des réponses plausibles en apparence, leur pertinence clinique réelle reste insuffisante avec un déséquilibre notable entre le volume de contenu généré et sa valeur informative effective.




Figure 6 - Analyse des indicateurs d'erreur de contenu par type de prompt pour le modèle Qwen2.5:32b

2. Niveau 2 : Tests d'inférences statistiques

Les résultats de ce niveau d'analyse consistent en la présentation des tests d'inférence statistique appliqués aux réponses générées par les modèles évalués. Pour chaque test sera présenté le détail des résultats suivit d'une interprétation et d'une conclusion explicite.

Modèle : LLaMa 3.1 8B Instruct

Les analyses présentées dans cette partie seront réalisées une fois l'ensemble des résultats d'évaluation par les experts reçus et consolidés.

Modèle : Gemma3 27b

Les analyses présentées dans cette partie seront réalisées une fois l'ensemble des résultats d'évaluation par les experts reçus et consolidés.

Modèle : Qwen2.5 :32b

a. Test de Friedman pour le score d'exactitude

Le test de Friedman a été réalisé afin d'évaluer si le type de reformulation de la prompt influence significativement le score de fidélité clinique (noté S_exact). Les trois conditions comparées étaient par conséquent les formulations narratives, condensées et reformulées. Le test met en évidence une différence significative entre les conditions avec $\chi^2(2) = 9.82$ et $p = 0.007$.

Comme $p < 0.05$, l'hypothèse nulle d'égalité des distributions est rejetée. Les résultats montrent par conséquent que le type de reformulation a un effet significatif sur les performances du modèle. Cela indique donc que les réponses du LLM ne sont pas totalement stables face aux variations de formulation du prompt. Des analyses post-hoc par tests de Wilcoxon signé-rangé avec correction de Bonferroni avec un alpha fixé à 0.017 ont ensuite été réalisées afin d'identifier quelles paires de reformulations différaient significativement.

Tableau 4 : récapitulatif des résultats post-hoc

Formulation comparées	P-value obtenues
Narratif vs Condensé	$p = 0.024$
Narratif vs Reformulé	$p < 0.001$
Condensé vs Reformulé	$p = 0.244$

Après correction de Bonferroni, seule la comparaison entre les formulations narratives et reformulées reste statistiquement significative. Les différences entre formulations narratives et condensées ainsi qu'entre formulations condensées et reformulées ne sont pas significatives. Ces résultats suggèrent que la reformulation du prompt peut modifier de manière importante les performances du modèle, mais que cet effet dépend du type de reformulation appliqué. La différence observée entre les formulations narratives et reformulées montre qu'un changement de structure ou de formulation de la question peut entraîner une variation significative de l'exactitude clinique produite par le modèle.

Cependant, l'absence de différence significative entre les formulations condensées et reformulées suggère que ces deux formats produisent des comportements relativement proches du modèle sur ce critère. La comparaison entre formulations narratives et condensées montre une tendance à la différence, mais celle-ci n'est pas suffisamment forte pour rester significative après correction multiple.

Dans l'ensemble, ces résultats soutiennent l'hypothèse d'une sensibilité du LLM à la reformulation des prompts. D'un point de vue clinique cela signifie qu'un même cas peut conduire à des performances différentes selon la manière dont la question est formulée. Cette instabilité représente un enjeu important pour l'utilisation fiable des LLM en aide au diagnostic clinique, car elle suggère que les réponses du modèle ne dépendent pas uniquement du contenu médical du cas mais également de la formulation linguistique utilisée.

b. Test de Friedman pour la confiance déclarée

Le test de Friedman a été réalisé afin d'évaluer si le type de reformulation de la prompt influence significativement le score de confiance déclaré par le modèle. Les trois conditions comparées étaient les formulations narratives, condensées et reformulées.

Le test de Friedman ne met pas en évidence de différence significative entre les trois conditions avec $\chi^2(2) = 0.56$ et $p = 0.755$.

Comme $p > 0.05$, l'hypothèse nulle d'égalité des distributions ne peut pas être rejetée. Les résultats suggèrent donc que le type de reformulation n'a pas d'effet significatif sur le niveau de confiance déclaré par le modèle. Des analyses post-hoc par tests de Wilcoxon signé-rangé avec correction de Bonferroni ($\alpha = 0.017$) ont ensuite été réalisées afin de vérifier d'éventuelles différences entre chaque paire de reformulations.

Tableau 5 : récapitulatif des résultats post-hoc

Formulation comparées	P-value obtenues
Narratif vs Condensé	$p = 0.557$
Narratif vs Reformulé	$p = 0.751$
Condensé vs Reformulé	$p = 0.610$

Aucune des comparaisons n'est statistiquement significative. Les scores de confiance restent donc globalement stables quelle que soit la reformulation du prompt. Ces résultats indiquent que contrairement au score de fidélité clinique, la confiance exprimée par le modèle varie peu selon la formulation de la question. Le modèle semble conserver un niveau de confiance similaire même lorsque ses performances changent significativement.

Ce résultat est particulièrement intéressant cliniquement car il suggère que le modèle peut produire des réponses de qualité différente selon le prompt tout en maintenant un niveau de confiance relativement constant. Cela signifie que la confiance déclarée du modèle ne semble pas être un indicateur fiable de la qualité réelle de la réponse.

Ces résultats montrent une dissociation globale entre exactitude et confiance c'est-à-dire que le modèle est sensible à la reformulation pour ses performances cliniques, mais pas pour le niveau de confiance qu'il affiche. Cette stabilité de la confiance malgré des variations de performance peut représenter un risque en contexte clinique, car une réponse moins exacte peut être formulée avec un niveau de confiance similaire à une réponse correcte.

c. Test Cochran Q pour les recommandations dangereuses et les informations inventées

Aucune recommandation dangereuse n'a été identifiée dans les réponses générées par le modèle, quel que soit le type de reformulation du prompt utilisé. La variable reco_dangereuse est restée égale à 0 pour l'ensemble des cas analysés. En conséquence, aucun test statistique comparatif n'a pu être réalisé pour ce critère, en raison de l'absence totale de variabilité dans les données. Ce résultat constitue un signal positif du point de vue de la sécurité clinique, suggérant que le modèle n'a pas proposé de prise en charge manifestement inadaptée, contre-indiquée ou susceptible d'entraîner un risque direct pour le patient dans les cas étudiés.

Le test de Q de Cochran a été réalisé afin d'évaluer si le taux d'informations inventées variait selon le type de reformulation du prompt (narratif, condensé ou reformulé). La variable analysée était binaire avec 0 = aucune information inventée et 1 = présence d'au moins une information inventée. Le test ne met pas en évidence de différence significative entre les trois conditions avec un $Q = 2.00$ et $p = 0.368$.

Comme $p > 0.05$, l'hypothèse nulle ne peut pas être rejetée. Les résultats suggèrent donc que le type de reformulation n'a pas d'effet significatif sur la probabilité que le modèle produise des informations inventées. Des analyses post-hoc par tests de McNemar ont ensuite été réalisées afin de comparer les reformulations deux à deux.

Tableau 6 : récapitulatif des résultats post-hoc

Formulation comparées	P-value obtenues
Narratif vs Condensé	$p = 1.000$
Narratif vs Reformulé	$p = 1.000$
Condensé vs Reformulé	$p = 1.000$

Aucune comparaison n'est significative. Les taux d'informations inventées restent donc similaires entre les trois types de reformulation. Ces résultats suggèrent que, dans ce jeu de données, les hallucinations du modèle ne semblent pas fortement influencées par la manière dont le prompt est formulé. Contrairement au score d'exactitude, qui variait significativement selon la reformulation, la tendance à introduire des informations non justifiées paraît relativement stable.

D'un point de vue clinique, ce résultat peut être considéré comme partiellement rassurant. Il indique que les variations de formulation du prompt n'augmentent pas significativement le risque d'hallucination dans cette expérience. Toutefois, l'absence de significativité ne signifie pas nécessairement l'absence totale d'effet. Avec un effectif limité ($N = 15$ cas), certaines différences faibles peuvent ne pas être détectées statistiquement. Dans l'ensemble, ces résultats suggèrent que la reformulation influence davantage la qualité et l'exactitude des réponses que la propension du modèle à inventer des informations.

d. Corrélation de spearman

La corrélation de Spearman a été utilisée afin d'évaluer si les niveaux de confiance déclarés par le modèle étaient associés à la qualité réelle des réponses évaluées par l'expert clinicien. Cette analyse repose sur la relation entre le score de confiance déclaré et le score de fidélité clinique S_{exact} . Les résultats de ce test sont un $\rho = 0.233$ et une $p = 0.00698$.

La corrélation observée est positive et statistiquement significative (car $p < 0.05$). Cela signifie qu'il existe une tendance générale selon laquelle les réponses associées à une confiance plus élevée présentent également une exactitude légèrement meilleure. Cependant, l'intensité de cette corrélation reste faible ($\rho = 0.233$). Cela signifie que même si la relation existe statistiquement, la confiance déclarée par le modèle explique très peu la qualité réelle des réponses.

La figure 7 montre graphique de dispersion confirme cette observation. Pour des niveaux de confiance très proches (généralement compris entre 0.85 et 0.95), il est observé une très forte variabilité des scores d'exactitude réels, allant de réponses totalement incorrectes ($S_{\text{exact}} = 0$) à des réponses parfaitement exactes ($S_{\text{exact}} = 1$). Cela montre que des réponses de qualité très différente peuvent être produites avec des niveaux de confiance quasiment identiques.




Figure 7 – Résultats corrélation spearman entre l'exactitude réelle et la confiance déclarée par le modèle

Ces résultats sont cohérents avec les analyses de calibration du niveau trois d'analyse vis-à-vis des métriques de qualité des réponses notamment l'Expected Calibration Error élevé ($ECE=0.359$) et le reliability diagram montrant une surconfiance importante. Ensemble, ces résultats suggèrent que le modèle conserve une légère capacité à ajuster sa confiance en fonction de la qualité de ses réponses mais que cette calibration reste globalement insuffisante pour un usage clinique fiable.

Plus concrètement, cela signifie que les scores de confiance fournis par le modèle ne peuvent pas être interprétés comme un indicateur robuste de fiabilité médicale. Même lorsqu'un niveau de confiance élevé est affiché, la réponse peut rester partiellement incorrecte, incomplète ou imprécise. Cette analyse met donc en évidence une calibration imparfaite des LLM étudiés soit que la confiance déclarée suit légèrement la qualité réelle des réponses mais de manière trop faible pour constituer un signal clinique fiable sans validation humaine complémentaire.

3. Niveau 3 : Métriques de qualité des réponses

a. BERTScore

Les analyses par BERTScore ont été réalisées sur les réponses générées par les trois modèles évalués (LLaMa 3.1 8B Instruct, Gemma3 27b et Qwen2.5:32b). Deux types de scores ont été calculés un score brut ("brut"), correspondant au BERTScore classique et un score rescalé ("rescale") qui est normalisé à l'aide d'une baseline afin de rendre les différences plus discriminantes. Trois dimensions ont été étudiées : la qualité des réponses par rapport aux éléments-clés attendus, la stabilité inter-répétitions, la stabilité face aux reformulations du prompt.

QUALITE DES REPONSES

Les scores F1 moyens bruts de qualité sont $F1=0.581$ pour LLaMa 3.1 8B Instruct, $F1=0.572$ pour Gemma3 27b et $F1=0.571$ pour Qwen2.5:32b.

Les scores rescalés associés sont $F1=-0.118$ pour LLaMa, $F1=-0.141$ pour Gemma3 et $F1=-0.146$ pour Qwen2.5:32b.

Étant donné que les trois modèles obtiennent des performances relativement proches concernant la similarité sémantique entre les réponses générées et les éléments-clés attendus. Les scores bruts autour de 0.57-0.58 traduisent une similarité sémantique modérée, suggérant que les modèles récupèrent une partie importante des informations pertinentes mais sans atteindre la totalité des éléments attendus. Les scores rescalés deviennent négatifs pour les trois modèles. Cela nous indique qu'une fois corrigée par la baseline du modèle BERTScore, la proximité sémantique réelle reste relativement limitée. Cela suggère que les réponses contiennent des éléments pertinents mais également beaucoup de contenu générique ou éloigné des formulations de référence.

Il est tout de même noté que le modèle LLaMa 3.1 8B Instruct présente légèrement les meilleurs résultats sur cette dimension mais les écarts restent faibles entre les trois modèles.

STABILITE INTER-REPETITIONS

Les scores F1 moyens bruts de stabilité inter-répétitions sont $F1=0.762$ pour LLaMa 3.1 8B Instruct, $F1=0.842$ pour Gemma3 27b et $F1=0.792$ pour Qwen2.5:32b.

Les scores rescalés associés sont $F1=0.364$ pour LLaMa, $F1=0.580$ pour Gemma3 et $F1=0.445$ pour Qwen2.5:32b.

Étant donné que les trois modèles montrent une forte stabilité entre les répétitions réalisées avec un même prompt. Les scores bruts élevés indiquent que les réponses produites lors des répétitions restent très proches sémantiquement. Gemma3 27b présente la stabilité la plus élevée, avec un F1 brut de 0.842 et un F1 rescalé de 0.580. Cela suggère que ce modèle produit les réponses les plus cohérentes d'une répétition à l'autre. Qwen2.5:32b montre également une bonne stabilité, tandis que LLaMa présente une stabilité légèrement plus faible mais restant élevée.

Ces résultats suggèrent qu'à température fixée à 0, les modèles conservent un comportement relativement déterministe et reproductible lorsqu'un même prompt est répété.

STABILITE FACE AUX REFORMULATIONS

Les scores F1 moyens bruts de stabilité inter-reformulations sont $F1=0.741$ pour LLaMa 3.1 8B Instruct, $F1=0.808$ pour Gemma3 27b et 0.773 pour Qwen2.5:32b.

Les scores rescalés associés sont $F1=0.308$ pour LLaMa, $F1=0.489$ pour Gemma3 et $F1=0.394$ pour Qwen2.5:32b.

Ces résultats nous permettent de conclure que les modèles conservent une similarité sémantique relativement élevée lorsque le prompt est reformulé. Les scores restent globalement élevés ce qui indique que les réponses produites gardent une structure et un contenu relativement proches malgré les modifications linguistiques des questions. Gemma3 27b présente une nouvelle fois les meilleurs résultats sur cette dimension, suggérant une plus grande robustesse aux variations de formulation. Cependant, ces résultats doivent être interprétés avec prudence. Une forte similarité BERTScore entre deux réponses ne garantit pas nécessairement une stabilité clinique réelle. Deux réponses peuvent rester proches lexicalement tout en différant sur certains éléments médicaux critiques. Inversement, des réponses formulées différemment peuvent rester cliniquement équivalentes. Ainsi, le BERTScore mesure principalement une proximité sémantique globale et non une exactitude clinique stricte.

Dans l'ensemble, les trois modèles présentent des profils relativement similaires en termes de qualité sémantique globale, mais diffèrent davantage sur les dimensions de stabilité.

Synthèse des résultats du BERTScore. Les trois modèles produisent des réponses sémantiquement cohérentes et stables entre répétitions. Gemma3 27B est le plus stable, aussi bien entre répétitions qu'entre reformulations. LLaMA obtient quant à lui les meilleurs scores de qualité brute. Cela dit, les scores restent modérés. Les modèles ne restituent pas encore avec précision les éléments clés attendus dans une réponse clinique. Le BERTScore mesure une similarité sémantique, pas une exactitude médicale. Il complète l'évaluation experte mais ne peut pas la remplacer.

b. ECE

Les métriques de calibration ont été utilisées afin d'évaluer si le niveau de confiance déclaré par le modèle correspond réellement à la qualité de ses réponses. La calibration a été mesurée à l'aide de l'Expected Calibration Error (ECE) ainsi qu'au moyen d'un reliability diagram représentant la relation entre confiance moyenne déclarée et exactitude réelle.

L'Expected Calibration Error (ECE) est égale à 0.359. Cette valeur relativement élevée indique une mauvaise calibration globale du modèle. On considère que lorsqu'un ECE est proche de 0 cela correspond à un modèle bien calibré dont le niveau de confiance reflète fidèlement la probabilité réelle d'obtenir une réponse correcte. Par conséquent, plus l'ECE est élevé plus l'écart entre confiance et performance réelle est important.

La figure 8 correspondant au Reliability Diagram confirme cette tendance. Les points observés sont nettement situés sous la diagonale idéale $y = x$ (trait en pointillé bleu) qui représenterait une calibration parfaite. Cela signifie que le modèle affiche un niveau de confiance systématiquement supérieur à son exactitude réelle.




Figure 8 - Reliability diagram entre l'exactitude réelle et la confiance moyenne

Concrètement, les réponses produites avec une confiance moyenne comprise entre environ 85 % et 90 % n'atteignent qu'une exactitude réelle proche de 50 %. Le modèle semble donc fortement surconfiant

et exprime un haut niveau de certitude même lorsque la qualité clinique réelle de la réponse reste modérée ou faible.

Ces résultats sont cohérents avec les analyses précédentes. Alors que les scores d'exactitude variaient significativement selon les reformulations du prompt, les scores de confiance restaient globalement élevés et relativement stables. Cette dissociation entre confiance et performance suggère que les scores de confiance fournis par le modèle ne constituent pas un indicateur fiable de la qualité réelle des réponses générées. Dans notre contexte, ce résultat est particulièrement préoccupant car un professionnel de santé pourrait interpréter un score de confiance élevé comme un signal de fiabilité, alors même que la réponse peut être partiellement incorrecte, incomplète ou imprécise. Cette surconfiance représente donc un risque en contexte d'aide au diagnostic clinique car elle peut renforcer artificiellement la crédibilité de réponses erronées.

Ces analyses mettent en évidence un problème important de calibration des LLM étudiés. Même si les modèles sont capables de produire des réponses cohérentes et relativement stables, leur niveau de confiance apparaît largement surestimé par rapport à leurs performances réelles. Ces résultats confirment les phénomènes de surconfiance déjà décrits dans la littérature sur les grands modèles de langage et soulignent la nécessité d'une validation humaine systématique avant toute utilisation clinique.

DISCUSSION

Les résultats obtenus lors de cette phase expérimentale confirment plusieurs des hypothèses formulées en amont et apportent des éléments quantitatifs inédits sur le comportement des LLM en contexte d'interprétation médicale. Pour Qwen 2.5 32B, modèle pour lequel la grille d'évaluation experte est disponible, trois constats principaux se dégagent : la reformulation du prompt influence significativement l'exactitude clinique des réponses ; la sécurité immédiate est préservée (absence de recommandations dangereuses) ; la calibration est insuffisante, avec une confiance auto-déclarée systématiquement surestimée par rapport à l'exactitude réelle. Sur les métriques automatiques, les trois modèles présentent une bonne stabilité sémantique inter-répétitions et inter-reformulations, mais une qualité modérée par rapport aux éléments cliniques attendus.

1. Limites des résultats

Plusieurs limites doivent être prises en compte dans l'interprétation de ces résultats.

La première est le **périmètre partiel de l'évaluation experte**. À ce stade, la grille multicritère n'est disponible que pour Qwen 2.5 32B. Les conclusions sur l'exactitude, la sécurité et les hallucinations ne peuvent donc pas être généralisées aux deux autres modèles, et la comparaison inter-modèles reste limitée aux métriques automatiques. Ce périmètre restreint est une contrainte liée au temps nécessaire à l'annotation clinique mais il fragilise la portée comparative des résultats.

La deuxième limite concerne la **puissance statistique**. Avec $N = 15$ cas les tests d'inférence sont sensibles aux valeurs extrêmes et à la distribution des scores. L'absence de significativité observée pour les variables binaires (reco_dangereuse et info_inventee) ne permet pas de conclure à l'absence d'effet. En effet, avec un effectif aussi réduit des différences cliniquement pertinentes peuvent ne pas atteindre le seuil statistique. Les résultats doivent donc être interprétés comme des tendances orientant l'analyse plutôt que comme des conclusions définitives.

La troisième limite porte sur la **représentativité du corpus clinique**. Les 15 cas sont issus d'annales d'endocrinologie et couvrent un spectre limité de pathologies. Les résultats ne sont pas généralisables à d'autres spécialités médicales. Le comportement des modèles pourrait différer sensiblement sur des cas plus ambigus ou moins bien représentés dans leurs données d'entraînement.

La quatrième limite concerne la **nature du score de confiance**. Ce score est auto-déclaré par le modèle en réponse à une instruction explicite dans le prompt. Il ne s'agit pas d'une probabilité calibrée au sens technique du terme mais d'une estimation subjective formulée en langage naturel. La comparaison de ce score entre modèles doit donc être interprétée avec prudence car un score de 85/100 de LLaMA 3.1 8B ne mesure pas la même chose qu'un score de 85/100 de Qwen 2.5 32B.

2. Comparaison avec la littérature

Les résultats obtenus s'inscrivent dans la continuité des travaux récents sur l'évaluation des LLM en contexte médical, tout en apportant des éléments de précision sur des dimensions peu explorées.

Sur la sensibilité au prompt, les résultats confirment les observations de Zhao et al. (2021), qui montrent que la performance d'un LLM peut varier fortement selon le format de la requête, indépendamment de son contenu médical. La différence significative observée entre les formulations narratives et reformulées ($p < 0.001$) illustre précisément ce phénomène dans un contexte clinique réel. Concrètement, un même cas clinique produit des réponses d'exactitude significativement différente selon la manière dont la question est posée. Ce résultat prolonge également les conclusions de Hager et al. (2024), qui documentent sur 2 400 cas réels la sensibilité des LLM à l'ordre et à la quantité d'informations fournies. Notre protocole permet d'aller plus loin en isolant l'effet de la reformulation comme variable expérimentale principale, toutes choses égales par ailleurs.

Sur la calibration, le résultat obtenu ($ECE = 0.359$ et $q = 0.233$) est cohérent avec les travaux de Guo et al. (2017) sur la surconfiance des réseaux de neurones modernes, et avec les observations de Nori et

al. (2023) sur GPT-4, dont la calibration, bien qu'améliorée par rapport aux versions précédentes, reste insuffisante pour des usages critiques.

Sur les hallucinations, l'absence de variation significative du taux d'informations inventées selon la reformulation ($p = 0.368$) suggère que les hallucinations observées sont davantage liées aux limites intrinsèques du modèle qu'à la formulation de la requête. Ce constat est cohérent avec la distinction proposée par Dang Anh-Hoang et al. (2025) entre hallucinations d'origine prompt réductibles par une meilleure formulation et hallucinations d'origine modèle qui persistent quelle que soit la qualité du prompt. En revanche, le niveau élevé de N_{ajout} (2.3 à 3.8 éléments non demandés par réponse) indique une tendance marquée à l'hallucination additive, comportement documenté dans la littérature comme particulièrement risqué en médecine en raison de la plausibilité rhétorique des informations ajoutées (Bender et al., 2021).

Sur la sécurité clinique, l'absence totale de recommandations dangereuses pour Qwen 2.5 32B est un résultat favorable qui distingue ce modèle des profils les plus risqués décrits dans la littérature. Hager et al. (2024) documentent des cas de non-respect des recommandations médicales par plusieurs LLM testés sur des cas réels. Notre résultat suggère qu'un modèle de grande taille peut présenter un profil de sécurité satisfaisant sur des cas d'endocrinologie standardisés tout en rappelant que ce résultat est limité à 15 cas et ne saurait constituer une validation clinique.

Sur les métriques automatiques, les scores BERTScore de stabilité inter-reformulations (F1 entre 0.41 et 0.808) indiquent que les modèles produisent des réponses sémantiquement proches malgré les variations de formulation. Ce résultat est favorable en apparence mais doit être mis en regard du score d'exactitude clinique car une cohérence sémantique élevée entre reformulations n'implique pas une exactitude clinique suffisante ce qui illustre le problème des hallucinations fluentes documenté notamment par Manakul et al. (2023) avec SelfCheckGPT. BERTScore mesure une proximité de surface mais il ne peut pas se substituer à une évaluation experte pour juger de la pertinence clinique réelle des réponses.

Au total, les résultats du projet LLMQ confirment et précisent trois dimensions d'évaluation. Premièrement qu'il y a une sensibilité au prompt présentant une source d'instabilité clinique. Deuxièmement qu'il y a une surconfiance systématique, celle-ci représentant un risque d'usage. Enfin en troisièmes, qu'il y a une dissociation entre plausibilité rhétorique et exactitude factuelle. Ces éléments soulignent la nécessité d'une évaluation experte systématique et d'une standardisation des pratiques d'interrogation avant tout déploiement responsable de LLM en contexte médical.

PERSPECTIVES

Les perspectives présentées dans cette section s'inscrivent dans la continuité directe des résultats obtenus. À ce stade, la grille d'évaluation experte n'est disponible que pour Qwen 2.5 32B. La priorité immédiate est la finalisation des évaluations de LLaMA 3.1 8B Instruct et Gemma3 27B par le Dr Jean Canarelli et l'interne Chjara-Maria Tomasi, ce qui permettra d'activer l'ensemble des analyses comparatives inter-modèles prévues dans le protocole. Les perspectives décrites ci-après s'articulent autour de deux axes : l'extension du protocole expérimental et clinique d'une part, l'enrichissement de l'analyse statistique et automatique d'autre part.

1. Perspectives cliniques et expérimentales

La première perspective est la complétion de la comparaison inter-modèles. Une fois les grilles de LLaMA 3.1 8B et Gemma3 27B finalisées il sera possible de tester directement les hypothèses H1 à H5 sur les trois modèles et d'identifier si les profils observés pour Qwen, c'est à dire sensibilité au prompt sur l'exactitude, stabilité sur la sécurité, surconfiance systématique, sont spécifiques à ce modèle ou constituent des caractéristiques partagées.

La deuxième perspective concerne l'extension des cas clinique. Le protocole actuel repose sur 15 cas d'endocrinologie. Une extension à d'autres spécialités tel que oncologie ou la cardiologie par exemple permettrait de tester la généralisation des résultats et d'identifier si la sensibilité au prompt est uniforme ou varie selon la complexité et l'ambiguïté des cas. L'inclusion de cas comportant des informations partielles ou contradictoires pourraient s'avérer plus proches des conditions réelles de pratique.

La troisième perspective (à long terme) est l'intégration de données réelles anonymisées. Le protocole actuel repose exclusivement sur des données synthétiques issues d'annales. L'utilisation de résultats réels (anonymisés) permettrait d'évaluer le comportement des modèles sur des cas dont la complexité et l'ambiguïté ne peuvent pas être entièrement reproduites par des données construites.

2. Perspectives statistiques et métriques

Sur le plan analytique, quatre métriques complémentaires sont envisagées pour enrichir l'évaluation au-delà de BERTScore et ECE.

ROUGE-L mesurera le recouvrement lexical entre les réponses produites sous différentes reformulations, en calculant la plus longue sous-séquence commune entre deux textes. Combiné à BERTScore, il permettra de distinguer deux formes d'instabilité, une instabilité de forme et une instabilité de fond. Plus concrètement, le modèle exprime le même contenu avec des mots différents (que ROUGE-L pénalise mais que BERTScore tolère) et le modèle change de contenu en profondeur (que les deux métriques pénalisent simultanément). Un cas présentant un ROUGE-L faible mais un BERTScore élevé sera interprété comme une variation stylistique sans impact clinique alors qu'un cas où les deux métriques chutent ensemble sera identifié comme cliniquement instable et fera l'objet d'une relecture experte approfondie.

SelfCheckGPT (Manakul et al., 2023) exploitera les trois répétitions de chaque prompt pour estimer automatiquement le risque d'hallucination sans référence externe. Une information stable dans les connaissances du modèle sera reproduite de façon cohérente sur les trois répétitions alors qu'une information hallucinée variera ou se contredira entre générations.

AlignScore (Zha et al., 2023) évaluera l'alignement factuel entre chaque réponse générée et le cas clinique fourni dans le prompt en quantifiant dans quelle mesure les affirmations du modèle sont ancrées dans les informations disponibles. À l'inverse de SelfCheckGPT (qui compare les générations entre elles), AlignScore détecte les affirmations introduites sans justification contextuelle.

L'ensemble de ces extensions analytiques vise un objectif commun qui consiste à réduire la dépendance à l'annotation experte manuelle tout en maintenant la rigueur clinique nécessaire à une évaluation valide des LLM en contexte médical.

CONCLUSION

Ce projet s'est donné pour ambition d'évaluer de manière rigoureuse et contrôlée l'impact de la reformulation du prompt sur la qualité, la sécurité et la stabilité des réponses produites par des grands modèles de langage dans un contexte d'aide à l'interprétation de résultats biologiques. La problématique centrale étant « **Dans quelle mesure la reformulation d'un même cas clinique influence-t-elle la qualité, la stabilité, la sécurité et la fiabilité des réponses d'un LLM, et quelles implications cette instabilité comporte-t-elle pour l'intégration responsable de ces outils en pratique médicale ?** » trouve dans les résultats obtenus des éléments de réponse concrets et quantifiés.

Les résultats disponibles apportent une réponse sur plusieurs dimensions. La reformulation de la prompt influence significativement l'exactitude clinique des réponses. Le test de Friedman appliqué à Qwen 2.5 32B nous confirme un effet significatif ($p = 0,007$) concentré sur la paire narrative versus reformulé ($p < 0,001$ après correction de Bonferroni). C'est-à-dire que pour un même cas clinique soumis sous deux formulations linguistiquement différentes mais médicalement équivalentes produit des réponses d'exactitude significativement différentes. Cette instabilité ne relève pas du raisonnement médical du modèle mais de sa sensibilité structurelle à la forme de la requête ce qui correspond à un phénomène documenté dans la littérature et confirmé ici dans un protocole expérimental contrôlé. La réponse à la problématique est donc affirmative soit que la reformulation influence substantiellement les réponses, et cette influence est suffisamment importante pour constituer un risque clinique réel.

Sur la sécurité le résultat est plus nuancé étant donné que l'absence de recommandations dangereuses pour Qwen 2.5 32B sur l'ensemble des cas étudiés constitue un signal favorable suggérant qu'un modèle présente un profil de sécurité satisfaisant sur des cas standardisés. Toutefois, ce résultat doit être interprété avec prudence car il est limité à 15 cas d'endocrinologie et l'absence d'erreur de sécurité sur un corpus restreint ne constitue pas une garantie en conditions réelles.

Sur la calibration, les résultats sont sans ambiguïté. La confiance auto-déclarée par les modèles est systématiquement surestimée et ce quelle que soit la qualité de la réponse. Elle est également faiblement corrélée à l'exactitude réelle ($\rho = 0,233$ et ECE = 0,359). Ce phénomène de surconfiance est cohérent avec la littérature existante et a une implication clinique directe. En effet, un professionnel de santé ne peut pas utiliser le score de confiance affiché par le modèle comme indicateur de fiabilité. Cette propriété lorsqu'on la combine à la sensibilité au prompt rend indispensable une supervision humaine systématique de toute réponse produite par un LLM en contexte médical.

Sur les métriques automatiques les trois modèles présentent une bonne cohérence sémantique entre reformulations et entre répétitions sans que cette cohérence ne garantisse une exactitude clinique suffisante.

Au-delà des résultats quantitatifs ce projet contribue à la réflexion méthodologique sur l'évaluation des LLM en santé. Le protocole mis en place qui combine une grille experte multicritère, des tests d'inférence adaptés aux mesures répétées et des métriques automatiques complémentaires, constitue une approche reproductible et extensible. Cela signifie qu'il est applicable à d'autres spécialités médicales et à d'autres modèles. La standardisation des pratiques d'interrogation des LLM en contexte clinique, que nous suggère les résultats, représente une piste concrète pour réduire la variabilité observée et améliorer la fiabilité des systèmes d'aide à la décision.

Les résultats de ce projet confirment en définitive ce que les cadres institutionnels du NIST (2023) et de l'OMS (2021) soulignent avec insistance soit que les performances apparentes d'un LLM sur des benchmarks standardisés ne suffisent pas à garantir un comportement fiable en conditions réelles. L'évaluation des LLM en santé ne peut pas se limiter à mesurer ce qu'un modèle sait mais doit mesurer comment il se comporte lorsque les conditions varient et dans quelle mesure il signale ses propres limites. C'est à cette condition, et à cette condition seulement, que l'intégration responsable de ces outils en pratique médicale devient envisageable.

Annexe1. Protocole de déploiement technique : LLaMa 3.1 8B Instruct

Le déploiement de LLaMA 3.1 8B Instruct est réalisé via le framework OpenLLM (BentoML), en environnement local. Les étapes principales sont :

1. Installation des dépendances : Python 3.10+, PyTorch, Transformers (HuggingFace), OpenLLM, BentoML.
2. Téléchargement du checkpoint via HuggingFace Hub (meta-llama/Meta-Llama-3.1-8B-Instruct), nécessitant une acceptation préalable de la licence Meta.
3. Démarrage du serveur via la commande : `openllm start meta-llama/Meta-Llama-3.1-8B-Instruct -port 3000`.
4. Interrogation via l'API locale : requêtes POST à `http://localhost:3000/v1/chat/completions`, au format JSON OpenAI.
5. Enregistrement des réponses brutes dans un fichier JSON structuré incluant `run_id`, `case_id`, `prompt_id`, répétition, timestamp, paramètres d'inférence et texte complet de la réponse.

Annexe2. Protocole de déploiement technique : Gemma3 27B

Le déploiement de Gemma3 27B est réalisé via le framework Ollama, en environnement local. Les étapes principales sont :

1. Téléchargement du modèle : `ollama pull gemma3:27b` (~17 Go)
2. Vérification des paramètres : `ollama show gemma3:27b` (confirme architecture, embedding 5 376, temperature native 1,0)
3. Lancement du serveur Ollama : `ollama serve` (écoute sur `http://localhost:11434`)
4. Interrogation via l'API locale : requêtes POST à `http://localhost:11434/api/chat`, avec spécification explicite de "temperature": 0.7 dans les options pour neutraliser la valeur native de 1,0
5. Enregistrement des réponses brutes dans un fichier JSON structuré incluant `run_id`, `case_id`, `prompt_id`, répétition, timestamp, paramètres d'inférence et texte complet de la réponse

Annexe3. Protocole de déploiement technique : Qwen 2.5 32B

Le déploiement de Qwen 2.5 32B est réalisé via le framework Ollama, en environnement local. Les étapes principales sont :

1. Téléchargement du modèle : `ollama pull qwen2.5:32b` (~20 Go)
2. Vérification des paramètres : `ollama show qwen2.5:32b` (confirme architecture qwen2, fenêtre de contexte 32 768 tokens, embedding 5 120)
3. Lancement du serveur Ollama : `ollama serve`
4. Interrogation via l'API locale : requêtes POST à `http://localhost:11434/api/chat`, avec timeout étendu à 600 secondes en raison du débordement partiel sur CPU (temps de réponse jusqu'à 4 minutes 15 secondes observé sur les cas complexes)
5. Enregistrement des réponses dans la même structure JSON que les autres modèles, avec les mêmes champs d'identification.

REFERENCES

- Ainslie, J., Lee-Thorp, J., de Jong, M., Zemlyanskiy, Y., Lebrón, F., & Sanghai, S. (2023). *GQA: Training generalized multi-query transformer models from multi-head checkpoints*. arXiv. <https://arxiv.org/abs/2305.13245>
- Alibaba Cloud. (2024). *Qwen/Qwen2.5-32B-Instruct* [Model card]. Hugging Face. <https://huggingface.co/Qwen/Qwen2.5-32B-Instruct>
- Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency* (pp. 610–623). ACM. <https://doi.org/10.1145/3442188.3445922>
- Collège des enseignants d'endocrinologie, diabète et maladies métaboliques. (2022). *Endocrinologie, diabétologie et maladies métaboliques* (6e éd.). Elsevier Masson.
- Collège des enseignants de médecine intensive-réanimation. (2023). *Médecine intensive, réanimation, urgences et défaillances viscérales aiguës* (8e éd.). Elsevier Masson.
- Dang, A.-H., Tran, V., & Nguyen, L.-M. (2025). Survey and analysis of hallucinations in large language models: Attribution to prompting strategies or model behavior. *Frontiers in Artificial Intelligence*, 8, Article 1622292. <https://doi.org/10.3389/frai.2025.1622292>
- European Parliament and Council of the European Union. (2016). *Regulation (EU) 2016/679 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data (General Data Protection Regulation)*. Official Journal of the European Union.
- European Parliament and Council of the European Union. (2024). *Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)*. Official Journal of the European Union.
- Garabet, R., Mackey, B. P., Cross, J., & Weingarten, M. (2024). ChatGPT-4 performance on USMLE Step 1 style questions and its implications for medical education: A comparative study across systems and disciplines. *Medical Science Educator*, 34, 145–152.
- Google DeepMind. (2024). *google/gemma-3-27b-it* [Model card]. Hugging Face. <https://huggingface.co/google/gemma-3-27b-it>
- Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. In D. Precup & Y. W. Teh (Eds.), *Proceedings of the 34th International Conference on Machine Learning* (Vol. 70, pp. 1321–1330). PMLR.
- Hager, P., Jungmann, F., Holland, R., Bhagat, K., Hubrecht, I., Knauer, M., Vielhauer, J., Makowski, M., Braren, R., Kaissis, G., & Rueckert, D. (2024). Evaluation and mitigation of the limitations of large language models in clinical decision-making. *Nature Medicine*, 30, 2613–2622. <https://doi.org/10.1038/s41591-024-03097-1>
- IBM. (n.d.). *Large language models (LLMs)*. <https://www.ibm.com/think/topics/large-language-models>
- Lin, S., Hilton, J., & Evans, O. (2022). TruthfulQA: Measuring how models mimic human falsehoods. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics* (Vol. 1, pp. 3214–3252). Association for Computational Linguistics.
- Llama Team. (2024). *The Llama 3 herd of models*. arXiv. <https://arxiv.org/abs/2407.21783>
- Manakul, P., Liusie, A., & Gales, M. J. F. (2023). *SelfCheckGPT: Zero-resource black-box hallucination detection for generative large language models*. arXiv. <https://arxiv.org/abs/2303.08896>

- Meta. (2024). *meta-llama/Llama-3.1-8B-Instruct* [Model card]. Hugging Face. <https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct>
- National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)*. U.S. Department of Commerce. <https://nvlpubs.nist.gov/nistpubs/ai/nist.ai.100-1.pdf>
- Nori, H., King, N., McKinney, S. M., Carignan, D., & Horvitz, E. (2023). *Capabilities of GPT-4 on medical challenge problems*.
- Ollama. (2024). *Ollama documentation*. <https://ollama.com/docs>
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Askell, A., Welinder, P., Christiano, P., Leike, J., & Lowe, R. (2022). *Training language models to follow instructions with human feedback*. arXiv. <https://arxiv.org/abs/2203.02155>
- Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). *Language models are unsupervised multitask learners*. OpenAI. https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf
- Shazeer, N. (2020). *GLU variants improve transformer*.
- Su, J., Lu, Y., Pan, S., Murtadha, A., Wen, B., & Liu, Y. (2021). *RoFormer: Enhanced transformer with rotary position embedding*.
- Touvron, H., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., Rodriguez, A., Joulin, A., Grave, E., & Lample, G. (2023). *LLaMA: Open and efficient foundation language models*. arXiv. <https://arxiv.org/abs/2302.13971>
- Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., Bhosale, S., et al. (2023). *Llama 2: Open foundation and fine-tuned chat models*. arXiv. <https://arxiv.org/abs/2307.09288>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems* (Vol. 30). <https://arxiv.org/abs/1706.03762>
- World Health Organization. (2021). *Ethics and governance of artificial intelligence for health*. <https://www.who.int/publications/i/item/9789240029200>
- World Health Organization. (2024). *Ethics and governance of artificial intelligence for health: Guidance on large multimodal models*. <https://www.who.int/publications/i/item/9789240096233>
- Zha, Y., Yang, Y., Li, R., & Hu, X. (2023). *AlignScore: Evaluating factual consistency with a unified alignment function*. arXiv. <https://arxiv.org/abs/2305.16739>
- Zhang, B., & Sennrich, R. (2019). *Root mean square layer normalization*. arXiv. <https://arxiv.org/abs/1910.07467>
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). *BERTScore: Evaluating text generation with BERT*. arXiv. <https://arxiv.org/abs/1904.09675>
- Zhao, T. Z., Wallace, E., Feng, S., Klein, D., & Singh, S. (2021). *Calibrate before use: Improving few-shot performance of language models*. arXiv. <https://arxiv.org/abs/2102.09690>